

Technical Report Data Science Competition

LOGIKA UI 2025

Pemodelan Low-Resource Domain Cultural Image Classification dengan DINOv3 dan Explainable AI



Disusun oleh:
Bob Kunanda
Haegen Quinston
Nathaniel Jonathan Rusli
DSC0118

BANDUNG, INDONESIA
2025

I. Pendahuluan

1.1 Latar Belakang

Indonesia dikenal sebagai salah satu negara dengan tingkat heterogenitas budaya tertinggi di dunia dengan lebih dari 1.300 suku bangsa yang tersebar dari Sabang sampai Merauke. Unsur budaya seperti rumah adat, artefak, dan pakaian tradisional menjadi identitas kultural setiap daerah. Namun, tidak semua suku memiliki dokumentasi visual yang memadai sehingga terdapat ketimpangan dalam representasi budaya di ruang digital dan risiko hilangnya sebagian warisan budaya. Oleh karena itu, inisiatif pelestarian digital menjadi penting untuk menjaga keberlanjutan identitas budaya melalui teknologi visual dan sistem klasifikasi berbasis citra seperti *deep learning* dalam bidang *computer vision* [1], [2].

Meskipun demikian, pengembangan sistem klasifikasi citra budaya menghadapi sejumlah tantangan teknis yang signifikan. Domain budaya Indonesia termasuk dalam kategori *low-resource domain*: jumlah citra budaya yang tersedia relatif terbatas, distribusi kelas yang tidak seimbang, dan terdapat variasi visual yang tinggi di dalam kelas yang sama. Selain itu, banyak elemen visual antarsuku yang memiliki kemiripan tinggi, misalnya pola atap rumah adat, ukuran kayu, atau ornamen kain yang mirip. Kurangnya dokumentasi yang sistematis juga menyebabkan *dataset* mengandung *label noise*, gambar duplikat, serta latar belakang yang tidak relevan yang berpotensi mengarahkan model pada *shortcut learning* [3]. Permasalahan tersebut tidak hanya berdampak pada penurunan akurasi, tapi juga berpotensi menghasilkan model yang bias dan tidak representatif sehingga berpotensi mengaburkan identitas budaya tertentu.

Di tengah tantangan tersebut, kemajuan arsitektur *deep learning* moden menyediakan beberapa pendekatan yang relevan untuk memodelkan *low-resource domain* dan *high variability* seperti budaya Indonesia. Convolutional Neural Network (CNN) memiliki kemampuan mengenali pola lokal, sedangkan Visual Transformer (ViT) mampu mempelajari relasi global antar-*patch* citra melalui mekanisme *self-attention*. Namun, pendekatan *self-supervised learning* (SSL) memberikan keuntungan tambahan dalam mempelajari representasi yang lebih

stabil dari data tidak berlabel. Di antara model tersebut, Distillation with No Labels (DINO), khususnya DINOv3, menonjol sebagai pilihan utama karena mampu menghasilkan representasi visual yang kuat, konsisten, dan sangat sesuai dengan karakteristik domain budaya Indonesia [4].

Dalam konteks budaya, pemilihan model tidak hanya ditentukan oleh akurasi klasifikasi, tapi juga oleh tingkat interpretabilitas untuk memastikan bahwa perhatian model terfokus pada elemen visual yang relevan, seperti bentuk arsitektur dan ornamen khas, bukan pada hal lain seperti latar belakang ataupun pepohonan. Interpretabilitas menjadi aspek yang sangat krusial dalam membangun kepercayaan terhadap publik dan para *stakeholder*. Dengan demikian, penelitian ini berfokus pada pengembangan *pipeline* model serta analisis interpretabilitas untuk menghasilkan klasifikasi citra budaya Indonesia yang akurat, dapat dijelaskan, dan dapat berkontribusi terhadap pelestarian warisan budaya nasional.

1.2 Tujuan dan Manfaat

Tujuan utama dari penelitian ini meliputi beberapa aspek sebagai berikut:

1. Merancang *pipeline* pengolahan data yang efektif dan kontekstual, mencakup tahap *preprocessing*, *augmentation*, dan strategi pelatihan model yang disesuaikan dengan karakteristik data.
2. Menginvestigasi kinerja DINOv3 sebagai model utama untuk klasifikasi citra budaya Indonesia, dengan EfficientNet-B3 dan ViT-B/16 sebagai *baseline* guna menilai keunggulan DINOv3 dan menentukan kecocokan model terhadap karakteristik dataset atau domain budaya.
3. Menganalisis interpretabilitas model untuk memastikan bahwa model berfokus pada komponen visual yang relevan secara budaya, seperti bentuk arsitektur, ornamen, dan pola khas, bukan pada bagian non-esensial seperti latar belakang.

Melalui pencapaian tujuan tersebut, penelitian ini diharapkan memberikan manfaat baik secara akademik maupun praktis. Secara akademik, penelitian ini berkontribusi pada pengembangan metode klasifikasi berbasis *deep learning* untuk domain data budaya yang kompleks. Secara praktis, hasil penelitian

diharapkan dapat menjadi dasar pengembangan sistem pelestarian budaya berbasis teknologi digital yang mampu menjaga keberagaman dan identitas budaya Indonesia di era modern.

1.3 Batasan Penelitian

Agar penelitian ini terarah dan sesuai dengan ruang lingkup yang dapat dicapai, maka penelitian ini memiliki beberapa batasan sebagai berikut:

1. Ruang lingkup data terbatas pada domain citra visual budaya Indonesia, meliputi objek seperti rumah adat, artefak, pakaian tradisional, dan *landmark* khas daerah.
2. Model yang diuji dibatasi pada tiga model *deep learning* modern sebagai representatif dari masing-masing keluarga model: EfficientNet-B3 (CNN), ViT-B/16 (ViT), dan DINOv3 (DINO).
3. Analisis interpretabilitas menggunakan *attention rollout* untuk model berbasis ViT dan Grad-CAM untuk model berbasis CNN guna menghasilkan dan menilai visualisasi area citra yang menjadi fokus prediksi.
4. Evaluasi kinerja model difokuskan pada metrik Macro F1-score.

II. Landasan Teori

2.1 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan arsitektur *deep learning* yang dirancang khusus untuk memproses data visual melalui operasi matematika konvolusi yang mengekstraksi fitur lokal dari citra. Secara matematis, operasi konvolusi dua dimensi didefinisikan sebagai:

$$Y_{i,j} = \sum_{m=0}^{h-1} \sum_{n=0}^{w-1} X_{i+m,j+n} \cdot K_{m,n} \quad (1)$$

di mana X adalah citra *input* dan K adalah *kernel*. CNN menggunakan *convolutional layer* untuk menghasilkan *feature map* yang menangkap pola spasial, *pooling layer* untuk menurunkan dimensi representasi sekaligus meningkatkan invariansi terhadap translasi, serta *fully connected layer* untuk

proses klasifikasi akhir. CNN belajar secara hierarkis, dimulai dari fitur sederhana seperti tepi dan tekstur hingga fitur kompleks seperti bentuk dan objek [5].

2.2 Visual Transformer (ViT)

Vision Transformer (ViT) merupakan arsitektur berbasis *Transformer* yang mengolah citra melalui pembagian citra ke dalam patch berukuran tetap sebelum diubah menjadi representasi vektor melalui *patch embedding*. ViT menerapkan *multi-head self-attention* yang secara matematis dirumuskan sebagai:

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}}) V \quad (2)$$

dengan $Q = XW_Q$, $K = XW_K$, dan $V = XW_V$. Mekanisme ini memungkinkan ViT memodelkan interaksi global antar-*patch* sehingga dapat menggambarkan hubungan spasial pada tingkat yang lebih luas dibandingkan CNN [6].

2.3 Self-Supervised Learning DINO dan DINOv3

Self-supervised learning (SSL) adalah pendekatan pembelajaran representasi tanpa memerlukan label eksplisit. Model dilatih dengan memecahkan *pretext task* sehingga model dapat menangkap struktur dan semantik alami dari data yang tidak berlabel [7]. Dalam konteks *computer vision*, SSL menjadi penting karena data visual sering memiliki variasi tinggi dan *labeling* yang mahal.

Keluarga model DINO (*Distillation with No Labels*) memperkenalkan mekanisme *teacher-student* untuk melatih *Vision Transformer* tanpa supervisi. DINO menerapkan dua augmentasi kuat (*views*) dari satu gambar: (1) *teacher* menghasilkan distribusi target dan (2) *student* dilatih untuk meniru distribusi tersebut. Proses *knowledge distillation* diformalkan sebagai Kullback-Leibler *divergence* (KL):

$$l_{distill} = KL(q_{tt}(x_t) || p_{ts}(x_s)) \quad (3)$$


dengan x_t merupakan *global view* untuk *teacher*, x_s merupakan *local* atau *global view* untuk *student*, q_{tt} merupakan keluaran *teacher* setelah *temperature*

sharpening τt , dan $p_{\tau s}$ merupakan keluaran *student* dengan *temperature* τs .

Distribusi *teacher* diperoleh dari *sharpened softmax*:

$$q_{\tau t}(z) = \frac{\exp(z/\tau t)}{\exp(zj/\tau t)} \quad (4)$$

Teacher diperbarui menggunakan Exponential Moving Average (EMA) dari parameter *student* sehingga proses *training* menjadi stabil tanpa memerlukan label [8].



Gambar 1. Diagram arsitektur *self-supervised learning* pada model DINO

Versi terbaru model DINO yaitu DINOv3 telah memberikan peningkatan signifikan dalam stabilitas pelatihan, kualitas representasi, dan skalabilitas *pretraining* melalui perbaikan normalisasi, desain *loss*, serta *pipeline multi-view* termasuk *multi-crop* dan *multi-resolution views* [4].

2.4 Explainable AI (XAI) dengan Grad-CAM

Explainable AI (XAI) dapat digunakan untuk memahami dasar pengambilan keputusan model melalui visualisasi area citra yang paling berkontribusi terhadap prediksi. Grad-CAM (Gradient-weighted Activation Mapping) merupakan metode *post-hoc* yang memanfaatkan gradien dari kelas target terhadap *feature map* pada *layer* tertentu untuk menghasilkan *heatmap* yang merepresentasikan tingkat kepentingan setiap wilayah dalam citra. Secara umum, Grad-CAM menghitung bobot pentingnya fitur melalui gradient teragregasi:

$$\alpha_k = \frac{1}{Z} \sum_i \sum_j \frac{\Delta y^{(c)}}{\Delta A^{k}_{ij}} \quad (5)$$

Di mana A_{ij}^k adalah aktivasi *feature map* ke- k , $y^{(c)}$ adalah skor kelas target, dan Z adalah faktor normalisasi. Peta Grad-CAM kemudian diperoleh dengan kombinasi linier:

$$L_{Grad-CAM}^{(c)} = ReLU\left(\sum_k \alpha_k A_k\right) \quad (6)$$

yang menghasilkan visualisasi area dengan kontribusi terbesar terhadap prediksi kelas [9].

2.4 Explainable AI (XAI) dengan *Attention Rollout*

Model berbasis Vision Transformer (ViT) memiliki teknik *attention rollout* yang memanfaatkan matriks *self-attention* dari layer Transformer untuk menelusuri aliran perhatian dari token *class* (CLS) ke seluruh *patch* citra. Proses *attention rollout* meliputi beberapa tahap: (1) merata-ratakan *attention* antar-*head*, (2) menambahkan komponen residual dengan identitas I , (3) melakukan normalisasi baris, serta (4) mengalikan *attention matrix* secara berurutan dari *layer* pertama hingga *layer* akhir. Secara matematis, untuk setiap layer l , *attention matrix* teragregasi dapat dituliskan:

$$\bar{A}^{(l)} = \frac{A^{(l)} + I}{\sum_j (A^{(l)} + I)_{ij}} \quad (7)$$

dengan *rollout attention* dihitung melalui:


$$R = \bar{A}^{(1)} \times \bar{A}^{(2)} \times \dots \times \bar{A}^{(l)} \quad (8)$$

Nilai pada baris pertama (token CLS) dari matriks R kemudian direkonstruksi ke bentuk spasial sesuai *grid patch* sehingga menghasilkan peta perhatian yang dapat divisualisasikan sebagai *heatmap*. Teknik ini memberikan gambaran global mengenai area citra mana yang paling memengaruhi representasi internal model Transformer [10].

III. Metodologi

3.1 Desain Sistem dan *Pipeline*

Proses pembangunan sistem klasifikasi citra dilakukan melalui beberapa tahap berurutan, dimulai dengan analisis data eksploratif (EDA), kemudian *preprocessing* serta augmentasi terhadap dataset. Selanjutnya, dataset dibagi menggunakan *stratified split* menjadi set pelatihan dan validasi. Beberapa model digunakan seperti DINOv3 sebagai model utama, serta EfficientNet-B3 dan ViT-B/16 sebagai *baseline* pembanding. *Classification head* dilatih pada data yang telah diproses dan performa model dipantau pada setiap epoch menggunakan metrik Macro F1-score. Model dengan performa terbaik disimpan dan digunakan untuk melakukan inferensi pada set uji sebagai prediksi akhir. Seluruh proses pelatihan dilakukan pada lingkungan Kaggle Notebook dengan akselerasi GPU NVIDIA T4 sebanyak dua unit ($T4 \times 2$).



Gambar 2. Diagram alir penelitian secara keseluruhan

3.2 Deskripsi Dataset dan Exploratory Data Analysis (EDA)

Dataset yang digunakan dalam penelitian ini berasal dari Data Science Competition (DSC) LOGIKA UI 2025, dengan total 2.196 citra (1.752 citra termasuk *training set* dan 444 citra termasuk *test set*) yang terdiri atas 5 kelas budaya Indonesia: Batak, Dayak, Javanese, Balinese, dan Minangkabau. Distribusi citra antarkelas tidak seimbang sebagaimana ditunjukkan pada Tabel 1.

Tabel 1. Distribusi jumlah citra per kelas pada *training set*

Kelas	Balinese	Batak	Dayak	Javanese	Minang
<i>Training Set</i>	776	95	69	249	563

Ukuran gambar pada dataset juga tidak seragam dengan berbagai variasi resolusi, dimulai dari yang sangat kecil (paling kecil berukuran 275 x 183 *pixels*) hingga yang berukuran besar (paling besar berukuran 10.005 x 6.561 *pixels*) dengan rasio aspek yang berbeda. Secara visual, dataset juga menunjukkan variasi pada pencahayaan, sudut pengambilan, hingga latar belakang yang tidak terkontrol.

	img1_name	img2_name	hash_diff
0	balinese_train_000021.jpg	balinese_train_000551.jpg	2
1	balinese_train_000021.jpg	balinese_train_000636.jpg	2
2	balinese_train_000103.jpg	balinese_train_000724.jpg	4
3	balinese_train_000330.jpg	balinese_train_000343.jpg	4
4	balinese_train_000489.jpg	balinese_train_000721.jpg	0

Gambar 3. Deteksi duplikat berdasarkan *hash difference*

Selain itu, terdapat isu duplikasi citra pada dataset sebanyak 77 gambar, baik dalam bentuk yang identik maupun *near-duplicate*, yang dideteksi menggunakan analisis *perceptual hashing* (pHash). Metode ini memungkinkan identifikasi citra yang sama atau hampir sama berdasarkan kesamaan struktur visual. Berdasarkan hasil analisis pHash, diketahui bahwa gambar duplikat tidak hanya berada pada kelas yang sama, tapi juga gambar yang sama dapat terduplikasi pada kelas-kelas yang berbeda. Untuk memastikan *cultural correctness*, Google Image Search dimanfaatkan sebagai sumber verifikasi eksternal serta membandingkan fitur visual khas sehingga gambar duplikat dapat dihapus sesuai pilihan kelas yang tepat (daftar gambar duplikat dapat dilihat pada Lampiran 1).



Gambar 4. Contoh misklasifikasi gambar duplikat lintas kelas pada *training set*

3.3 *Preprocessing* dan *Augmentasi* Data

Tahap *preprocessing* dan *augmentasi* dirancang untuk mengatasi karakteristik dataset budaya Indonesia yang bersifat *low-resource* dan memiliki variabilitas tinggi, baik dari segi pencahayaan, sudut pengambilan gambar, latar belakang, maupun perbedaan ukuran dan rasio aspek citra. Seluruh citra baik pada *training set* maupun *test set* di-*resize* ke resolusi 320×320 *pixels* agar konsisten dengan kebutuhan model berbasis Vision Transformer dan untuk memastikan bahwa detail arsitektural seperti pola atap, ukiran kayu, atau motif kain tetap terjaga tanpa kehilangan informasi semantik penting. Setelah *resizing*, citra dinormalisasi menggunakan statistik ImageNet agar sesuai dengan parameter pretraining pada model baseline dan model utama.



Gambar 5. Visualisasi *image resizing* menjadi 320×320 *pixels*

Augmentasi pada *training set* disusun secara *domain-aware* untuk meningkatkan kemampuan generalisasi model terhadap keragaman visual khas budaya Indonesia. Transformasi yang digunakan meliputi:

1. *Random Resized Crop*, digunakan untuk menyimulasikan variasi jarak dan pembingkai (*framing*) objek. Transformasi ini penting karena foto rumah adat dan artefak sering diambil dari jarak berbeda atau sebagian terhalang objek lain. Dengan mempertahankan 80–100% area asli, model dilatih untuk mengenali bentuk arsitektur meskipun sebagian struktur terpotong.
2. *Random Horizontal Flip*, diterapkan untuk menambah keragaman orientasi tanpa menghilangkan makna budaya. Transformasi ini aman untuk domain arsitektur dan pakaian tradisional karena orientasi horizontal tidak mengubah identitas budaya.
3. *Random Rotation*, dibatasi hingga 15° , berguna untuk memodelkan variasi sudut pengambilan gambar di lapangan. Pembatasan derajat rotasi memastikan integritas bentuk arsitektural tetap terjaga sehingga sinyal semantik seperti kontur atap dan motif tidak terdistorsi.
4. *Color Jitter*, dengan variasi *brightness* dan *contrast* sebesar 0,2 yang digunakan untuk meningkatkan ketahanan model terhadap variasi pencahayaan alami. Citra budaya sering diambil pada kondisi eksternal yang sangat bervariasi, misalnya siang terik, cuaca mendung, atau pencahayaan museum sehingga augmentasi ini penting untuk mencegah model terlalu bergantung pada kondisi pencahayaan tertentu.

Seluruh augmentasi tersebut hanya diterapkan pada *training set* untuk memperkaya distribusi sampel dan meningkatkan kemampuan generalisasi model. Sementara itu, data validasi dan uji hanya diterapkan transformasi *resize* dan normalisasi agar evaluasi performa tetap objektif dan bebas dari distorsi akibat augmentasi.

3.4 Model dan Arsitektur

Sebagai tolok ukur dalam perbandingan model, EfficientNet-B3 dan ViT-B/16 dijadikan sebagai model *baseline* pembanding. Kedua arsitektur ini


mewakili ‘keluarga’ arsitektur CNN modern dan Transformer *supervised* secara berturut-turut. Untuk memastikan perbandingan yang adil, kedua *baseline* ini diimplementasikan menggunakan strategi ekstraksi fitur (*feature extraction*) yang identik, yaitu rangka utama (*backbone*) model *pre-trained* (ImageNet) dibekukan, dan hanya *classification head* khusus (nn.Linear) yang dilatih.

Adapun model utama yang digunakan dalam penelitian ini adalah DINOv3 dengan *checkpoint* facebook/dinov3-vith16plus-pretrain-lvd1689m. Varian *Huge* (~840 juta parameter) dipilih sebagai kompromi optimal antara kapasitas representasi *self-supervised* yang masif dan keterbatasan komputasi GPU, menghindari model berparameter 7 miliar (*giant*) yang terlalu besar. Strategi ekstraksi fitur diterapkan dengan membekukan seluruh rangka (*backbone*) DINOv3, untuk memanfaatkan fitur umum yang kuat dari DINOv3 sekaligus meminimalkan biaya komputasi dan risiko *overfitting*.

Pelatihan difokuskan hanya pada *classification head* kustom (nn.Linear) menggunakan *optimizer* AdamW, yang dipilih karena kemampuannya menangani *weight decay* secara efektif pada arsitektur Transformer. Proses ini dijalankan selama 10 *epoch* dengan *learning rate* 1e-3 dan *batch size* 32, yang ditetapkan sebagai titik optimal antara stabilitas gradien dan alokasi memori GPU. Seluruh proses pelatihan juga diakselerasi menggunakan Automatic Mixed Precision (AMP) untuk efisiensi memori dan kecepatan komputasi *float16*.

3.5 Pemodelan dan Prediksi

Untuk proses evaluasi, dataset dibagi menggunakan strategi *hold-out* dengan rasio 80% untuk pelatihan dan 20% sisanya untuk validasi. Pembagian ini tidak dilakukan secara acak, melainkan menggunakan *stratified sampling* (*stratify=targets*). Pendekatan ini esensial untuk memastikan bahwa distribusi proporsional setiap kelas tetap terjaga secara identik di subset pelatihan dan validasi. Pelatihan dan validasi dilakukan sebanyak 10 *epoch*, dan model yang dipilih adalah yang mencapai Macro-F1 Score tertinggi pada set validasi disimpan. Pendekatan ini menjamin bahwa model yang dipilih memiliki kemampuan generalisasi terbaik.



Gambar 6. Diagram Pembagian Data Latih/Validasi per Kelas

3.6 Metrik Evaluasi

Macro F1-Score menjadi metrik evaluasi yang digunakan untuk persoalan ini yang menghitung rata-rata F1-Score dari semua kelas tanpa pembobotan (*unweighted mean*). Macro F1-Score dihitung sebagai rata-rata dari $F1_k$ untuk C jumlah kelas:

$$Macro F1 = \frac{1}{C} \sum_{k=1}^C F1_k \quad (9)$$

F1-Score sendiri menghitung *harmonic mean* antara *precision* dan *recall* hasil klasifikasi data per kelas yang didefinisikan secara matematis sebagai berikut:


$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k} \quad (10)$$

Penggunaan metrik Macro F1-Score mampu memberikan bobot penilaian yang setara pada setiap kelas (baik kelas mayoritas maupun minoritas) sehingga kemampuan model dapat diukur dengan tetap menyeimbangkan *precision* dan *recall* secara adil terlepas dari adanya ketidakseimbangan distribusi data.

3.7 Interpretasi Visual XAI

Untuk memastikan bahwa model tidak hanya menghasilkan prediksi yang akurat tetapi juga dapat dijelaskan secara visual, penelitian ini menerapkan pendekatan interpretabilitas berbasis Grad-CAM (Gradient-weighted Class Activation Mapping) untuk model berbasis CNN dan *attention rollout* untuk model berbasis ViT. Evaluasi dilakukan pada sejumlah citra yang dipilih secara

acak dari *test set* (untuk menguji generalisasi model) dengan karakteristik visual yang beragam, seperti variasi pencahayaan, komposisi bangunan, dan kompleksitas ornamen. *Heatmap* yang dihasilkan memungkinkan analisis kualitatif mengenai apakah model memusatkan perhatian pada komponen budaya yang seharusnya seperti bentuk atap, struktur bangunan, atau pola ornamen. *Shortcut learning* juga dapat teridentifikasi ketika model secara keliru berfokus pada elemen *noise* seperti latar belakang, pepohonan, atau bayangan. Area yang semakin merah mengindikasikan area tersebut diberikan perhatian lebih oleh model, sebaliknya area berwarna biru semakin tidak diperhatikan (dapat dilihat lebih jelas pada Gambar 7).



Gambar 7. Contoh *heatmap* dan panduan *attention weight*

IV. Analisis Hasil Eksperimen dan Pengujian


4.1 Hasil Metrik Evaluasi Model

Setelah melalui tahap eksperimen, evaluasi performa terhadap model yang diuji termasuk ViT-B/16, EfficientNet-B3, dan DINOv3 menggunakan metrik Macro F1-Score ditunjukkan pada Tabel 2. Terdapat juga *multi classification confusion matrix* berisi *recall* dari ketiga model yang ditunjukkan pada Gambar 8.

Tabel 2. Perbandingan Macro F1-Score masing-masing model

Model	Macro F1-Score
ViT-B/16	0,6923
EfficientNet-B3	0,7677
DINOv3	0,9510

Berdasarkan data skor pada Tabel 2, ViT-B/16 mencatatkan skor terendah, yaitu 0,6923, dan EfficientNet-B3 mencatatkan skor 0,7677. Sementara DINOv3 menunjukkan keunggulan performa yang sangat signifikan, dengan mencapai skor 0,9510. Terdapat disparitas performa yang jelas antara model utama dengan kedua model *baseline*.



Gambar 8. *Confusion matrix* masing-masing model


Confusion Matrix pada Gambar 8 menunjukkan *precision* dan *recall* antar kelas untuk setiap jenis model (dapat dilihat lebih jelas pada Lampiran 2). Meninjau model pertama, Model ViT-B/16 menunjukkan performa terendah dengan persebaran *false positive* dan *false negative* tertinggi. Kelas Batak menjadi tantangan terbesar bagi model ini, dengan *recall* hanya 44,44%. Model ini menunjukkan kesalahan klasifikasi yang substansial, tidak hanya salah memprediksi Batak sebagai Minangkabau (33,33%) tetapi juga sebagai Balinese (22,22%). Kelas Javanese juga memiliki *recall* yang rendah (58,00%), dengan bias prediksi utama ke Minangkabau (30,00%).

EfficientNet-B3 menunjukkan tingkat kebingungan (*confusion*) yang moderat. Model ini secara khusus kesulitan mengklasifikasikan kelas Batak (*recall* 75,00%) dan Dayak (*recall* 69,23%). Matriks ini menunjukkan adanya bias prediksi yang kuat ke arah kelas Minangkabau; 20,00% citra Batak dan 23,08% citra Dayak salah diklasifikasikan sebagai Minangkabau.

Model DINOv3 menunjukkan konsistensi prediksi tertinggi di semua kelas. Hampir seluruh nilai *recall* melampaui 90%, dengan *recall* terendah tercatat pada kelas Batak (88,89%). Kesalahan klasifikasi yang terjadi bersifat relatif minor dan distribusinya relatif merata.

4.2 Hasil *Heatmap* XAI

Evaluasi dan analisis kualitatif terhadap fokus visual masing-masing model menggunakan *heatmap* ditunjukkan pada Gambar 9 (terlihat lebih jelas pada Lampiran 3).



Gambar 9. Hasil *heatmap* XAI berdasarkan model

Model *baseline* ViT-B/16 menunjukkan pola atensi yang cenderung tersebar (*diffuse*), tidak konsisten, dan seringkali tidak tepat. Pada banyak sampel (contohnya Test_037.jpg, Test_306.jpg), *heatmap* terlihat tidak terstruktur dan gagal menyoroti area semantik yang jelas.

Meskipun terdapat perbedaan dalam interpretasi (Grad-CAM), model EfficientNet-B3 juga memperlihatkan kapabilitas yang memadai dalam mengidentifikasi area penting. Fokusnya sering kali selaras dengan DINOv3 (contohnya Test_057.jpg). Namun demikian, intensitas atensi DINOv3 tampak masih lebih spesifik dan terpusat, terutama pada aspek khas budaya tersebut, misalnya pada contoh Test_150.jpg, DINOv3 berhasil menangkap fitur ciri khas atap rumah adat dan pakaian adat, sedangkan EfficientNet-B3 hanya berhasil menangkap fitur ciri khas pakain adat.

Meninjau hasil *heatmap* DINOv3, model secara konsisten menunjukkan superioritas dalam melokalisasi fitur semantik yang paling diskriminatif. Atensi model ini terlihat sangat terpusat dan presisi pada komponen budaya yang relevan. Sebagai ilustrasi, pada citra rumah adat (Test_057.jpg dan Test_214.jpg), DINOv3 memfokuskan atensinya secara spesifik pada struktur atap, yang merupakan pembeda utama kelas tersebut. Pada contoh citra artefak berupa batu penanda (Test_037.jpg), model berhasil fokus pada simbol, aksara Jawa, dan tulisan “agung” yang sering muncul pada kelas Jawa. Pada contoh alat musik (Test_169.jpg) yaitu gamelan, model berhasil fokus pada bilahan dan corak pada gamelan untuk membedakan asal gamelan (misal corak Jawa dengan Bali).

4.3 Analisis Perbandingan Metrik Evaluasi dan XAI Heatmap


Analisis komparatif antara metrik *recall* dan *heatmap* XAI menunjukkan pola kinerja yang konsisten serta bias spesifik pada ketiga model klasifikasi. Secara umum, kelas Bali dan Minangkabau memperoleh tingkat *recall* tertinggi pada seluruh model, terutama karena proporsi data yang lebih besar yang menyediakan keragaman fitur yang kaya untuk dipelajari.

Meskipun demikian, pola kesalahan klasifikasi menunjukkan bahwa tidak semua model mampu memanfaatkan informasi visual secara seimbang. EfficientNet-B3 tampak memiliki bias kuat ke kelas Minangkabau saat memprediksi citra Dayak, Batak, dan Jawa, sedangkan ViT-B/16 juga menunjukkan bias serupa dan kerap salah mengenali Batak sebagai Bali.

Pada evaluasi keseluruhan, EfficientNet-B3 memang memperoleh macro F1-score yang lebih tinggi dibanding ViT-B/16 dan menghasilkan heatmap yang relatif lebih fokus. Hal ini dimungkinkan oleh arsitekturnya yang efisien dan modern sehingga mampu menangkap detail tekstur arsitektural dengan cukup stabil. Namun, fokus CNN yang terutama mengandalkan pola lokal tetap menjadi keterbatasan utama ketika menghadapi variasi bentuk global dan struktur ruang yang kompleks pada citra budaya. Di sisi lain, ViT-B/16 secara teoretis unggul dalam menangkap relasi global, tetapi *patch size* yang besar membuatnya mudah kehilangan detail penting dan, tanpa *pretraining* berskala besar seperti yang

digunakan DINOv3, model ini lebih mudah terkecoh oleh kemiripan siluet antar kelas.

Kedua model baseline tersebut pada akhirnya masih tertinggal dari DINOv3, yang memperoleh representasi lebih seimbang antara detail lokal dan konteks global melalui *pretraining self-supervised multi-view* dan penggunaan *register tokens* sehingga mampu mengurangi bias visual dan menghasilkan prediksi yang lebih stabil pada domain budaya. DINOv3 menunjukkan performa yang jauh lebih konsisten dan kuat, mencapai *recall* rata-rata di atas 90%, serta mempertahankan kestabilan prediksi meskipun terdapat kemiripan visual antar kelas. Walaupun masih terdapat ambiguitas minor, yang tercermin dari kecenderungan memprediksi Dayak sebagai Minangkabau serta Batak sebagai Minangkabau dan Bali, tingkat bias ini jauh lebih kecil dan tidak mengganggu kinerja keseluruhan model. Stabilitas kinerja dan ketahanannya terhadap pola *shortcut* menjadikan DINOv3 sebagai model yang paling ideal dalam skenario klasifikasi arsitektur adat ini.



Gambar 10. *Heatmap* rumah adat minangkabau, dayak, dan batak

Analisis XAI Heatmap mendukung temuan tersebut. Model DINOv3 cenderung fokus pada bagian atap bangunan dan mengabaikan bagian bawah atau kaki bangunan yang sebenarnya memuat informasi pembeda yang penting (seperti yang terlihat pada Gambar 10). Meskipun begitu, DINOv3 cenderung mengekstraksi area atap dengan cara yang lebih konsisten dan informatif sehingga meminimalisir kesalahan akibat kemiripan bentuk atap antar kelas. Kemampuan

ini menunjukkan bahwa DINOv3 tidak hanya memiliki kinerja kuantitatif yang tinggi, tapi juga pola perhatian visual yang lebih stabil.

V. Penutup

5.1 Kesimpulan

Penelitian ini bertujuan untuk mengevaluasi dan membandingkan kinerja 3 arsitektur *deep learning* modern berbeda, yaitu DINOv3 (*self-supervised*), EfficientNet-B3 (*CNN-supervised*), dan ViT-B/16 (*ViT-supervised*) dalam skenario klasifikasi citra budaya Indonesia yang kompleks dan bersifat *low-resource*. Berdasarkan analisis hasil eksperimen, dapat ditarik beberapa kesimpulan utama:

1. Telah berhasil dirancang sebuah *pipeline* pengolahan data yang efektif dan kontekstual. Strategi yang mencakup pembersihan data duplikat dan salah label lintas kelas, standarisasi resolusi, serta augmentasi *domain-aware* terbukti krusial dalam menangani karakteristik *dataset* budaya yang bersifat *low-resource*, tidak seimbang, dan bervariasi tinggi.
2. Investigasi kinerja DINOv3 sebagai model utama menunjukkan keunggulan yang sangat signifikan dibandingkan dengan *baseline*. DINOv3 mencapai Macro F1-Score 0,9510, jauh melampaui EfficientNet-B3 (0,7677) dan ViT-B/16 (0,6923). Temuan ini mengonfirmasi kecocokan DINOv3 untuk domain budaya Indonesia, yang didukung oleh *recall* rata-rata di atas 90% dan ketahanan (*robustness*) yang tinggi terhadap kemiripan visual antar kelas.
3. Analisis XAI berhasil memastikan fokus model. Teridentifikasi bahwa model *baseline* terutama ViT-B/16 masih rentan terhadap *shortcut learning*, ditunjukkan dengan atensi pada *heatmap* terhadap latar belakang atau pola lainnya yang bukan merupakan ciri khas budaya. Sebaliknya, DINOv3 terbukti fokus pada komponen visual yang relevan secara lebih presisi dan semantik, meminimalkan kesalahan akibat kemiripan visual dan memenuhi kriteria interpretabilitas yang diinginkan.

5.2 Rekomendasi

Pengembangan model klasifikasi citra arsitektur memerlukan pendekatan yang komprehensif untuk memastikan bahwa sistem mampu mengenali pola visual secara akurat dan konsisten. Hasil evaluasi menunjukkan bahwa performa model sangat dipengaruhi oleh kualitas data, area fokus yang diperhatikan model, serta keberagaman fitur visual yang tersedia pada dataset. Kondisi ini menegaskan pentingnya strategi peningkatan yang tidak hanya berfokus pada penguatan arsitektur model, tapi juga pada optimalisasi fitur relevan dan peningkatan kemampuan generalisasi. Dengan mempertimbangkan temuan tersebut, berikut beberapa rekomendasi yang dapat diterapkan:

1. Beberapa langkah pengembangan dapat dipertimbangkan untuk meningkatkan akurasi model klasifikasi arsitektur. Salah satu pendekatan yang menjanjikan adalah penggunaan metode deteksi Region of Interest seperti YOLO untuk memastikan bahwa model hanya memproses bagian bangunan yang relevan. Strategi ini memungkinkan sistem memfokuskan perhatian pada fitur-fitur penting seperti atap, ornamen, pilar, dan struktur bagian bawah bangunan sehingga gangguan dari latar belakang dapat diminimalkan.
2. Selain itu, penambahan data yang menampilkan bagian bawah bangunan, termasuk kaki bangunan dan elemen struktural pendukung, berpotensi meningkatkan kemampuan model dalam mengenali variasi bentuk ketika bagian atap tidak terlihat dengan jelas. Pendekatan ini juga membantu model memahami ciri khas arsitektur secara lebih menyeluruh, terutama pada kelas yang memiliki kemiripan bentuk atap.
3. Kualitas dataset perlu ditingkatkan melalui penggunaan sumber yang lebih andal, penyeimbangan jumlah data antarkelas, dan pemilihan citra dengan sudut pandang serta kondisi visual yang konsisten.
4. Terakhir, pengujian model pada dataset eksternal dari sumber yang berbeda diperlukan untuk memastikan bahwa performa model stabil dan tidak bergantung pada karakteristik dataset tertentu. Dengan menerapkan langkah-langkah ini, sistem diharapkan mampu mencapai performa klasifikasi yang lebih baik dan lebih robust terhadap variasi data.

DAFTAR PUSTAKA



- [1] R. Ilabakho and R. Rasmita, “Preserving the cultural heritage of Indonesian society through digital preservation in libraries,” *J. Knowl. Garden*, vol. 3, no. 1, 2025, doi: 10.21776/ub.knowledgegarden.2025.3.1.32.
- [2] R. A. Kambau, Z. A. Hasibuan, and M. O. Pratama, “Classification for multiformat object of cultural heritage using deep learning,” in *Proc. 3rd Int. Conf. Informatics and Computing (ICIC)*, Palembang, Indonesia, Oct. 2018, pp. 1–5, doi: 10.1109/IAC.2018.8780557.
- [3] M. Ikhsan and M. Rahardi, “Image-based classification of Indonesian traditional houses using a hybrid CNN–SVM algorithm,” *J. Appl. Inf. Comput.*, vol. 9, no. 5, pp. 2303–2309, Oct. 2025, doi: 10.30871/jaic.v9i5.10864.
- [4] O. Siméoni, P. Lambert, H. Touvron, and M. Cord, “DINOv3: Self-supervised learning for vision at unprecedented scale,” *arXiv:2508.10104*, Aug. 2025.
- [5] A. Krizhevsky, I. Sutskever, and G. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Proc. NIPS*, 2012.
- [6] A. Dosovitskiy *et al.*, “An image is worth 16×16 words: Transformers for image recognition at scale,” in *Proc. ICLR*, 2021.
- [7] X. Chen and K. He, “Exploring simple Siamese representation learning,” in *Proc. CVPR*, 2021.
- [8] M. Caron *et al.*, “Emerging properties in self-supervised vision transformers,” in *Proc. ICCV*, 2021.
- [9] R. R. Selvaraju *et al.*, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proc. ICCV*, 2017.
- [10] S. Abnar and W. Zuidema, “Quantifying attention flow in transformers,” in *Proc. ACL*, 2020, pp. 4190–4197.

LAMPIRAN


Lampiran 1. Daftar *File* Duplikat yang Terdeteksi pHash

	img1_name	img2_name	hash_diff
0	balinese_train_000021.jpg	balinese_train_000551.jpg	2
1	balinese_train_000021.jpg	balinese_train_000636.jpg	2
2	balinese_train_000103.jpg	balinese_train_000724.jpg	4
3	balinese_train_000330.jpg	balinese_train_000343.jpg	4
4	balinese_train_000489.jpg	balinese_train_000721.jpg	0
5	balinese_train_000551.jpg	balinese_train_000636.jpg	4
6	balinese_train_000760.jpg	batak_train_000054.jpg	0
7	balinese_train_000761.jpg	batak_train_000038.jpg	0
8	balinese_train_000762.jpg	batak_train_000036.jpg	0
9	balinese_train_000764.jpg	dayak_train_000038.jpg	0
10	balinese_train_000765.jpg	javanese_train_000072.jpg	0
11	balinese_train_000766.jpg	javanese_train_000061.jpg	0
12	balinese_train_000767.jpg	javanese_train_000064.jpg	0
13	balinese_train_000768.jpg	javanese_train_000084.jpg	4
14	balinese_train_000768.jpg	javanese_train_000115.jpg	0
15	balinese_train_000769.jpg	javanese_train_000194.jpg	0
16	balinese_train_000770.jpg	javanese_train_000174.jpg	0
17	balinese_train_000771.jpg	minangkabau_train_000333.jpg	0
18	balinese_train_000772.jpg	minangkabau_train_000377.jpg	0
19	balinese_train_000773.jpg	minangkabau_train_000134.jpg	0
20	balinese_train_000774.jpg	minangkabau_train_000423.jpg	0
21	balinese_train_000776.jpg	minangkabau_train_000314.jpg	0
22	batak_train_000004.jpg	batak_train_000072.jpg	0
23	batak_train_000010.jpg	javanese_train_000019.jpg	4
24	batak_train_000010.jpg	javanese_train_000154.jpg	4
25	batak_train_000010.jpg	javanese_train_000226.jpg	0
26	batak_train_000011.jpg	batak_train_000083.jpg	0
27	batak_train_000013.jpg	batak_train_000088.jpg	0
28	batak_train_000015.jpg	batak_train_000074.jpg	0
29	batak_train_000016.jpg	batak_train_000084.jpg	0
30	batak_train_000019.jpg	batak_train_000029.jpg	0
31	batak_train_000055.jpg	javanese_train_000213.jpg	0
32	batak_train_000056.jpg	minangkabau_train_000155.jpg	0
33	batak_train_000065.jpg	javanese_train_000012.jpg	0
34	batak_train_000067.jpg	minangkabau_train_000409.jpg	0
35	batak_train_000081.jpg	minangkabau_train_000012.jpg	0
36	batak_train_000085.jpg	minangkabau_train_000411.jpg	0
37	batak_train_000092.jpg	javanese_train_000242.jpg	0
38	dayak_train_000003.jpg	dayak_train_000030.jpg	0
39	dayak_train_000004.jpg	minangkabau_train_000254.jpg	0
40	dayak_train_000052.jpg	javanese_train_000100.jpg	0
41	dayak_train_000057.jpg	dayak_train_000059.jpg	0
42	dayak_train_000067.jpg	minangkabau_train_000015.jpg	0
43	javanese_train_000003.jpg	javanese_train_000129.jpg	0
44	javanese_train_000004.jpg	minangkabau_train_000459.jpg	0
45	javanese_train_000010.jpg	javanese_train_000084.jpg	2
46	javanese_train_000018.jpg	javanese_train_000151.jpg	0
47	javanese_train_000019.jpg	javanese_train_000154.jpg	0
48	javanese_train_000019.jpg	javanese_train_000226.jpg	4
49	javanese_train_000020.jpg	javanese_train_000231.jpg	0
50	javanese_train_000021.jpg	javanese_train_000062.jpg	0
51	javanese_train_000037.jpg	minangkabau_train_000017.jpg	0
52	javanese_train_000065.jpg	minangkabau_train_000200.jpg	4
53	javanese_train_000065.jpg	minangkabau_train_000416.jpg	0
54	javanese_train_000084.jpg	javanese_train_000115.jpg	4
55	javanese_train_000130.jpg	javanese_train_000219.jpg	0
56	javanese_train_000154.jpg	javanese_train_000226.jpg	4
57	javanese_train_000232.jpg	minangkabau_train_000021.jpg	0
58	javanese_train_000232.jpg	minangkabau_train_000180.jpg	4
59	javanese_train_000244.jpg	minangkabau_train_000170.jpg	0
60	javanese_train_000246.jpg	minangkabau_train_000503.jpg	0
61	javanese_train_000248.jpg	minangkabau_train_000550.jpg	0
62	javanese_train_000249.jpg	minangkabau_train_000517.jpg	0
63	minangkabau_train_000021.jpg	minangkabau_train_000180.jpg	4
64	minangkabau_train_000023.jpg	minangkabau_train_000346.jpg	0
65	minangkabau_train_000024.jpg	minangkabau_train_000302.jpg	0
66	minangkabau_train_000026.jpg	minangkabau_train_000543.jpg	0
67	minangkabau_train_000027.jpg	minangkabau_train_000218.jpg	0
68	minangkabau_train_000029.jpg	minangkabau_train_000250.jpg	0
69	minangkabau_train_000030.jpg	minangkabau_train_000533.jpg	0
70	minangkabau_train_000034.jpg	minangkabau_train_000061.jpg	0
71	minangkabau_train_000035.jpg	minangkabau_train_000289.jpg	0
72	minangkabau_train_000036.jpg	minangkabau_train_000374.jpg	0
73	minangkabau_train_000075.jpg	minangkabau_train_000245.jpg	0
74	minangkabau_train_000200.jpg	minangkabau_train_000416.jpg	4
75	minangkabau_train_000204.jpg	minangkabau_train_000244.jpg	2
76	minangkabau_train_000401.jpg	minangkabau_train_000476.jpg	4


Lampiran 2. *Confusion Matrix* Hasil Evaluasi Model Training









ViT-B/16 Confusion Matrix




Lampiran 3. *Heatmap* XAI Masing-Masing Model



Input Image			
DINOv3			
ViT-B/16			
EfficientNet-B3			
Test_214.jpg	Test_057.jpg	Test_306.jpg	

Lampiran 4. Diagram Alir Penelitian Secara Keseluruhan



Lampiran 5. Diagram Pembagian Data Latih/Validasi per Kelas

