




Pemodelan Low-Resource Domain Cultural Image Classification dengan DINOv3 dan Explainable AI

Proposed by
Over Under 35.5

Logika UI 2025 Data Science Competition



Haegen Q.



Nathaniel J.R.



Bob K.



Indonesia memiliki warisan suku dan budaya yang kaya

> 1300 suku



Dokumentasi digital terbatas



Risiko kehilangan identitas budaya

Deep learning sebagai solusi cultural digital preservation

Pembuatan sistem klasifikasi otomatis dapat menjadi solusi untuk memetakan, mendigitalisasi, serta melestarikan citra kebudayaan secara sistematis, namun...

- 1 Dokumentasi visual belum merata, terstandarisasi, dan seringkali terbatas
- 2 Jumlah citra sedikit, tidak seimbang, dan kualitas sangat bervariasi
- 3 Variasi visual seperti lighting, background, dan angle foto sangat tinggi
- 4 Kemiripan bentuk antarbudaya misal atap rumah adat

Key Objective




Membangun sistem klasifikasi yang robust terhadap low-resource domain seperti budaya Indonesia disertai analisis XAI untuk memastikan model fokus pada ciri khas budaya yang tepat



Workflow diagram secara keseluruhan



Seluruh tahapan dimulai dari EDA hingga interpretasi XAI diimplementasikan untuk memenuhi objektif kasus klasifikasi budaya




Gambaran umum terhadap dataset yang digunakan




Dataset mencakup 2.196 gambar dengan 1.752 gambar termasuk training set dan 444 gambar termasuk test set

Distribusi data training set dan test set



Dataset tersebar menjadi 5 kelas budaya di Indonesia yang tidak merata



Variasi gambar baik dari sisi visual maupun sisi lain seperti ukuran dan aspek rasio



Dataset kebudayaan yang digunakan memiliki **berbagai tantangan** seperti data kebudayaan Indonesia lain pada umumnya

Tingkat variasi citra pada dataset yang begitu tinggi

Angle yang berbeda untuk objek gambar yang sama



Variasi warna dan tone yang berbeda-beda pada gambar dataset



Perbedaan fokus seperti rumah, pakaian, alat musik, dan artefak dari suatu budaya



Ukuran dan aspek rasio gambar pada dataset yang beragam dan ekstrem

Gambar terbesar dan terkecil dataset



Width 10005 pixels
Height 6561 pixels




Width 275 pixels
Height 183 pixels

Resize tanpa menghilangkan informasi penting



5.184 × 3.456 pixels

resized




320 × 320 pixels

Deteksi duplicates dan near duplicates pada dataset menggunakan pHash



Terdeteksi terdapat **77 pasang gambar duplikat** baik pada kelas yang sama, maupun lintas kelas

Alur deteksi duplikat pada seluruh gambar dataset berdasarkan perbedaan hash antargambar



Perfect duplicates (hash difference = 0)



batak_train_000016.jpg



batak_train_000084.jpg

Near duplicates (hash difference = 4)



balinese_train_000330.jpg



balinese_train_000343.jpg



Duplikat pada kelas yang dan kelas yang berbeda membutuhkan handling berbeda



Dataset duplikat ditangani untuk menghilangkan noise bagi model tanpa menghilangkan informasi penting

#1 Handling duplicates padak kelas yang sama



batak_train_000011.jpg



batak_train_000083.jpg



javanese_train_000010.jpg



javanese_train_000084.jpg

Hapus **salah satu** duplikat

#2 Handling duplicates pada ≥ 2 kelas yang berbeda



dayak_train_000067.jpg



minangkabau_train_000015.jpg

Duplikat yang sama pada kelas **Minangkabau** dan kelas **Dayak**



Berkas:Desa Budaya Pampang.jpg - Wikipedia

5.484x3.655

Wikipedia




File:Desa Budaya Pampang.jpg - Wikipedia

5.484x3.655

Wikipedia

Ternyata milik kebudayaan **Dayak**



Hapus gambar di kelas **Minangkabau**, **biarkan** gambar di kelas **Dayak**

Simulasi variansi visual data budaya melalui augmentasi data



Mengatasi keterbatasan dataset *low-resource* melalui penerapan 4 varian augmentasi data yang strategis

Citra Mentah



#1 Random Horizontal Flip



#2 Random Color Jitter



#3 Random Resized Crop



#4 Random Rotate (15°)



Baseline model yang digunakan sebagai perbandingan




Model EfficientNet-B3 dari family model CNN dan ViT-B/16 dari family model ViT dijadikan sebagai baseline studi kasus perbandingan terhadap DINOv3

EfficientNet-B3 (Modern Convolutional Neural Network)

Menggunakan convolutional layer untuk mengekstraksi pola spasial, pooling layer untuk mereduksi dimensi dan meningkatkan invariansi, serta fully connected layer sebagai tahap klasifikasi akhir.

Melakukan ekstraksi fitur tepi dan tekstur lokal melalui **operasi konvolusi**

Fitur compound scaling pada EfficientNet-B3




ViT-B/16 (Vision Transformer)

Membagi citra ke dalam patch berukuran tetap sebelum diubah menjadi representasi vektor melalui *patch embedding*

Patch-patch ini diperlakukan sebagai **urutan token** dan diproses oleh arsitektur **Transformer Encoder murni**. ViT memiliki **bias induktif yang minim** terhadap citra

Arsitektur high-level dari ViT




Mengapa DINOv3?



DINOv3 dengan kemampuannya menjadi model utama yang cocok dengan dataset kebudayaan Indonesia low-resource domain


Ilustrasi konsep self-supervised teacher-student pada model DINOv3




Multi-crop



Global views



Local views



Key reasons



1. **Self-supervised multi-view learning** menghasilkan representasi kuat meskipun **data terbatas**
2. **Stabil terhadap variabilitas visual** tinggi akibat multi-view
3. Menangkap **detail lokal** serta **konteks global** secara seimbang melalui mekanisme **register tokens**
4. **Lebih tahan terhadap shortcut learning** dibandingkan model supervised karena dapat **training tanpa label**
5. **Generalisasi lebih baik** pada domain budaya akibat **pretraining dalam skala besar**




Pelatihan berimbang melalui *stratified split* & validasi F1-Score



Menjaga proporsi kelas dengan penerapan stratified split 80/20, dan menilainya secara setara menggunakan Macro F1-Score

Stratified Split sebagai distributor data yang konsisten

Metode yang esensial agar memastikan distribusi proporsional 80/20 setiap kelas tetap terjaga secara identik di subset pelatihan dan validasi



Holdout 80/20 memastikan model dapat tergeneralisasi

Pelatihan dan validasi dilakukan sebanyak 10 epoch, dan model yang dipilih adalah yang mencapai Macro-F1 Score tertinggi pada set validasi disimpan

Jumlah epoch
Training dan Validation

10

Kriteria
Saving
Model

Max(Macro F1)

Macro F1-Score mampu memberi nilai yang non-diskriminatif

$$Macro\ F1 = \frac{1}{C} \sum_{k=1}^C F1_k$$

Penggunaan metrik Macro F1-Score mampu memberikan bobot penilaian yang setara pada setiap kelas sehingga kemampuan model dapat diukur dengan tetap **menyeimbangkan precision dan recall secara adil terlepas dari adanya ketidakseimbangan distribusi data**



Perbandingan nilai F1 untuk setiap model



Dengan menggunakan metrik Macro F1-Score, berikut adalah hasil evaluasi dari ketiga model

Tabel perbandingan Macro F1-Score antar model

Model	Macro F1-Score
ViT-B/16	0,6923
EfficientNet-B3	0,7677
DINOv3 🏆	0,9510


DINOv3 mendapatkan nilai F1 yang secara signifikan **jauh lebih besar** dibandingkan dengan model **ViT-B/16** dan **EfficientNet-B3**

Perbandingan hasil confusion matrix untuk setiap model



Confusion matrix digunakan untuk menilai performa model per kelas dan memahami pola kesalahan prediksi

Perbandingan confusion matrix menggunakan nilai recall




● **Balinese dan Minangkabau** merupakan kelas yang **paling mudah dikenali oleh model**

● **Kesalahan prediksi terbesar** terjadi pada kelas **Batak, Dayak, dan Jawa**, yang secara konsisten cenderung **diklasifikasikan sebagai Minangkabau**

Analisis pasca XAI berbasis visualisasi heatmap



Analisis XAI melalui visualisasi heatmap memberikan pemahaman yang lebih mendalam mengenai bagaimana model menangkap, memproses, dan memusatkan perhatian pada informasi visual yang relevan.



Hasil heatmap XAI

ViT-B/16

1. Attention pattern yang menyebar dan tidak konsisten
2. Heatmap sering tidak terstruktur
3. Terdapat kegagalan menyoroti fitur budaya yang relevan

EfficientNet-B3

1. Fokus lebih baik dan stabil dibandingkan ViT
2. Kadang selaras dengan DINOv3 pada citra tertentu
3. Masih kurang spesifik dan menangkap satu elemen budaya tertentu

DINOv3

1. Menunjukkan stabilitas interpretasi pada sampel dan kelas yang beragam
2. Fokus paling presisi dan terpusat pada fitur budaya yang paling diskriminatif
3. Mampu menyoroti detail halus seperti bentuk atap, aksara/symbol artefak, hingga corak tertentu



Analisis komparatif metrik dengan heatmap XAI



Secara keseluruhan, baik dari segi metrik maupun XAI, DINOv3 berperforma sangat baik meskipun membutuhkan training tambahan pada ciri tertentu

Key points of insights


Kedua baseline **gagal memanfaatkan data secara seimbang** dan terbukti rentan terhadap **shortcut learning** yang dipicu oleh kemiripan visual.

Patch size besar membuat ViT-B/16 **kehilangan detail fitur**, sehingga model mudah **terkecoh siluet**.

EfficientNet **unggul dalam tekstur lokal**, namun **gagal pada struktur global**.

Mekanisme *pretraining self-supervised multi-view* dan penggunaan *register tokens* pada DINOv3 terbukti mampu **mengurangi bias visual** serta **menghasilkan prediksi yang jauh lebih stabil**.


Ambiguitas minor masih terjadi pada model DINOv3



minangkabau_train_000190.jpg



dayak_train_000057.jpg



batak_train_000764.jpg

DINOv3 masih ambigu pada kelas Batak dan Dayak akibat kecenderungan **mengabaikan kaki bangunan** yang sebenarnya memuat **informasi pembeda** lebih lanjut.

Walau begitu, DINOv3 sudah **mengekstraksi area atap** dengan konsisten sehingga **meminimalisir kesalahan akibat kemiripan bentuk atap antar kelas**.



Pipeline Kontekstual: Kunci Mengatasi Data Low-Resource & Imbalanced



Dominasi Kinerja DINOv3: Performa F1-Score 0,9510, Jauh Melampaui Baseline



Validasi XAI: DINOv3 Fokus Tepat, tidak Rentan Shortcut Learning



YOLOv8

Penggunaan metode deteksi Region of Interest seperti YOLO dapat membantu model memfokuskan perhatian pada bagian bangunan yang relevan dan mengurangi gangguan dari latar belakang.



Penambahan data yang menampilkan bagian bawah bangunan dapat meningkatkan kemampuan model mengenali ciri arsitektur saat bagian atap tidak terlihat jelas.



Peningkatan kualitas dataset dapat dilakukan melalui pemilihan sumber terpercaya, penyeimbangan jumlah sampel, dan konsistensi sudut pandang citra.



Pengujian menggunakan dataset eksternal diperlukan untuk memastikan performa model tetap stabil dan tidak bergantung pada karakteristik dataset tertentu.





Terima Kasih!
