




Seiring berkembangnya zaman dan teknologi, produksi film kian meningkat


Jumlah film yang dirilis setiap tahun meningkat pesat, mencerminkan kemajuan teknologi produksi dan distribusi serta meningkatnya peminat...

Tren jumlah film yang dirilis setiap tahunnya berdasarkan data




Tren median popularitas film per tahun

Median popularitas film relatif stabil di awal abad ke-20, namun melonjak tajam sejak era 2010-an...



Distribusi popularitas film berdasarkan jumlahnya

Distribusi popularitas sangat timpang: mayoritas film berpolaritas rendah, hanya sedikit yang berhasil mencapai level populer...



Apakah genre?

Apa saja faktor yang
memengaruhi popularitas
film?

Apakah tahun dan
bulan rilis?

Apakah bahasa pada
film?

Atau faktor lainnya?

Behind the Hype: Analisis Data untuk Memahami Faktor Penentu Popularitas Film

Informatics Festival Data Analysis Competition

Tim LastWorgxhx



Maheswara Bayu
Kaindra



Nathaniel
Jonathan Rusli



Peter
Wongsoredjo

Berikut merupakan dataset yang kami gunakan untuk analisis

Dataset yang kami gunakan masih memiliki baris duplikat dan juga missing value

Dataset: Movie (12999 baris x 6 kolom)

	movie_title	genre_label	language	summary	popularity	release_date
0	Ace Ventura: When Nature Calls	Crime,Comedy,Adventure	en	Summoned from an ashram in Tibet, Ace finds hi...	28.877	1995-11-10
1	The Wave	Thriller	no	Although theorised, no one is really ready whe...	28.675	2015-08-28
2	Spotlight	NaN	en	The true story of how the Boston Globe uncover...	13.601	2015-11-06
3	The Medallion	Thriller,Fantasy,Action,Comedy	en	A Hong Kong detective suffers a fatal accident...	17.180	2003-08-15
4	Caro diario	NaN	it	Nanni Moretti recalls in his diary three slice...	6.270	1993-10-12
5	Half Nelson	Drama	en	Despite his dedication to the junior-high stud...	10.650	2006-08-11
6	Layer Cake	NaN	en	When a seemingly straight-forward drug deal go...	14.166	2004-09-30
7	Sorcerer	Adventure,Thriller	en	Four men from different parts of the globe, al...	18.015	1977-06-24
8	Six Days Seven Nights	Adventure,Action,Comedy,Romance	en	When Quinn, a grouchy pilot living the good li...	18.586	1998-06-12
9	The Birdcage	Comedy	en	A gay cabaret owner and his drag queen compani...	11.131	1996-03-08

Object	Float	Object
--------	-------	--------

Jumlah value unique pada dataset

```
movie_title nunique: 9652
genre_label nunique: 1876
language nunique: 43
summary nunique: 9985
popularity nunique: 8502
release_date nunique: 6111
```

Jumlah missing value pada dataset

```
movie_title      0
genre_label      2000
language         0
summary          5
popularity       0
release_date     0
dtype: int64
```

Number of Duplicated Data
Dalam Jumlah Baris

3008

Menangani kualitas data sebelum analisis lebih lanjut

Dataset awal mengandung duplikasi dan missing values sehingga diperlukan pembersihan agar hasil analisis lebih valid

Handling duplicated data pada dataset

Menghapus seluruh data duplikat

12999
Baris Data



9991
Baris Data

Menghilangkan 3008 baris duplikat (23,14%)

Handling missing values pada masing-masing fitur memiliki perlakuan yang berbeda

1 **Fitur Summary:** Di-drop seluruhnya karena hanya terdapat 5 baris tanpa summary

2 **Fitur Language**

	movie_title	genre_label	language	summary	popularity	release_date
8513	The Adventures of André and Wally B.	Family,Animation,Comedy	xx	There's nothing like a restful nap in a pleasa...	11.077	1984-12-17

Menurut standar ISO, tidak ada kode language XX sehingga row di-drop

3 **Fitur Genre:** Di-fill menggunakan **Sentence-BERT (SBERT)** dengan **logistic regression** dan **k-nearest neighbors**

	movie_title	genre_label	language	summary	popularity	release_date	final_genre
2	Spotlight		en	The true story of how the Boston Globe uncover...	13.601	2015-11-06	[Drama, Thriller]
3	The Medallion	[Thriller, Fantasy, Action, Comedy]	en	A Hong Kong detective suffers a fatal accident...	17.180	2003-08-15	[Thriller, Fantasy, Action, Comedy]
4	Caro diario		it	Nanni Moretti recalls in his diary three slice...	6.270	1993-10-12	[Comedy, Drama]
5	Half Nelson	[Drama]	en	Despite his dedication to the junior-high stud...	10.650	2006-08-11	[Drama]

Untuk memudahkan proses analisis, kami melakukan pembersihan data lebih lanjut dan membuat fitur baru dari fitur-fitur dasar dataset

Fitur genre: membuat fitur genre_count dan konversi genre_label menjadi dummy variables (multi-hot encoding)

movie_title	genre_count	is_action	is_adventure	is_animation	is_comedy	is_crime	is_drama	is_family	is_fantasy	is_history	is_horror	is_music	is_mystery	is_romance	is_science_fiction	is_tv_movie	is_thriller	is_war	is_western
0 Ace Ventura: When Nature Calls	3	0	1	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0
1 The Wave	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
2 Spotlight	2	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	1	0	0

Fitur language: menghilangkan/mapping kode bahasa yang redundan dan sudah tidak valid

```
array(['en', 'no', 'it', 'fr', 'de', 'hi', 'ja', 'ko', 'es', 'zh', 'cn',  
      'th', 'ru', 'sv', 'pt', 'hu', 'fi', 'da', 'eu', 'ml', 'ar', 'is',  
      'pl', 'et', 'fa', 'sr', 'id', 'uk', 'ab', 'tr', 'cs', 'ro', 'nl',  
      'el', 'la', 'te', 'nb', 'sh', 'bn', 'af', 'xx', 'bs', 'he'],  
      dtype=object)
```

```
alias_mapping = {  
    'cn': 'zh',  
    'sh': 'sr'  
}
```

Kode 'cn' dan 'zh' sama-sama merujuk pada bahasa Mandarin


Kode 'sh' sudah deprecated berdasarkan ISO 639-1 (pada tahun 2000)

Fitur release_date: membuat fitur release_season (fall, summer, autumn, winter), release_year, dan release_month

movie_title	release_date	release_year	release_month	release_decade	release_season
0 Ace Ventura: When Nature Calls	1995-11-10	1995	11	1990	fall
1 The Wave	2015-08-28	2015	8	2010	summer
2 Spotlight	2015-11-06	2015	11	2010	fall
3 The Medallion	2003-08-15	2003	8	2000	summer
4 Caro diario	1993-10-12	1993	10	1990	fall

Alur kerja kami dalam menganalisis dataset movie


Setelah melakukan preprocessing terhadap data, kami melontarkan berbagai business questions beserta hipotesisnya, lalu melakukan eksperimen menggunakan metode yang tepat untuk mendapatkan hasil



BQ1: Bagaimana efek jumlah genre terhadap popularitas?

Karena popularitas bukan pengukuran absolut, kami menggunakan korelasi Spearman untuk menilai kekuatan dan arah hubungan dengan variabel lain

Spearman correlation selalu menunjukkan korelasi positif antara jumlah genre terhadap popularitas sejak 1990



Tidak terdapat hubungan korelasi yang jelas antara jumlah genre dengan popularitas pada tahun 1950–1990

Tahun 1950 – 1990

Median ρ 0,087

Median p-value 0,496

Terdapat korelasi positif antara jumlah genre dengan popularitas pada tahun 1990 – 2022 dengan 17 dari 33 tahun menunjukkan korelasi yang signifikan, terutama setelah tahun 2010

Tahun 1990 – 2022

Median ρ 0,161


Median p-value 0,048

Note: $\rho < 0$ mengindikasikan korelasi negatif, $\rho = 0$ mengindikasikan tidak berkorelasi, dan $\rho > 0$ mengindikasikan korelasi positif

BQ1: Bagaimana efek jumlah genre terhadap popularitas?

Kami menggunakan Mann-Whitney U Test dalam menguji perbedaan signifikan antar kelompok karena distribusi popularitas film yang tidak selalu normal

Mann-Whitney U Test menunjukkan film dengan multi-genre memiliki distribusi popularitas yang lebih besar dibandingkan single-genre



27 dari 33 tahun

Film dengan multi-genre memiliki distribusi popularitas yang lebih besar dibandingkan single-genre

9 dari 33 tahun


Menunjukkan perbedaan popularitas yang signifikan secara statistik ($p < 0,05$) antara film multi-genre dan single-genre

Note: $r_{rb} < 0$ mengindikasikan hubungan negatif, $r_{rb} = 0$ mengindikasikan tidak ada hubungan, dan $r_{rb} > 0$ mengindikasikan hubungan positif

BQ2: Apakah seiring meningkatnya jumlah genre terdapat diminishing return?

Karena distribusi popularitas condong ke ekor panjang (skewed), Quantile Regression dipakai untuk menganalisis pengaruh faktor pada median

Garis pada quantile regression melandai setelah genre count melebihi 5 yang dikonfirmasi dengan semakin kecilnya perubahan pada koefisien



Berdasarkan koefisien spline basis function di bawah, tampak bahwa masih terdapat peningkatan median popularitas pada ≥ 5 genre, tapi efeknya lebih kecil dibandingkan rentang 3 – 5 genre (mengindikasikan diminishing return)



Basis Function	Coef.	p-value
Intercept	10,59	0,000
1 – 2 genre	2,58	0,000
3 – 5 genre	11,85	0,000
≥ 5 genre	9,29	0,035

BQ3: Genre mana yang menguatkan popularitas, dan mana yang melemahkannya?

Apriori digunakan untuk mengidentifikasi co-occurrence antar genre film. Threshold support 0.02 memastikan hanya kombinasi genre yang muncul di $\geq 2\%$ film dianalisis, sehingga fokus pada pola yang cukup signifikan dan relevan.

Kombinasi action-adventure-sci-fi/fantasy (blockbuster) paling efektif meningkatkan popularitas film.


Genre berbasis comedy-drama-romance konsisten lemah dalam menarik popularitas.



BQ4: Bagaimana musim/tanggal rilis memengaruhi genre dan popularitas film?

Histogram distribusi popularitas per bulan digunakan untuk mengidentifikasi periode puncak rilis film, dengan membandingkan rata-rata antar rentang waktu.

Popularitas film memuncak pada periode Mei hingga pertengahan Juli, sementara bulan lain relatif stabil.





BQ4: Bagaimana musim/tanggal rilis memengaruhi genre dan popularitas film?

Analisis distribusi bulan (Mei–Juli) menunjukkan lonjakan popularitas yang signifikan, konsisten dengan pola musiman: periode Summer (Juni–Agustus) menjadi pusat rilis film besar dan puncak popularitas, memperkuat hubungan antara strategi penentuan bulan rilis dengan dampak komersial film.

Sejak 1980-an, tren summer blockbusters memicu lonjakan popularitas yang menjadikan musim panas sebagai periode dengan kenaikan tertinggi dibanding musim lain.

Di era modern, gap antar-musim makin melebar, dengan summer dan spring mendominasi lonjakan popularitas dibanding musim lain.




Note: Lonjakan popularitas yang signifikan pada dekade 2010–2020 menyebabkan analisis dipisah menjadi dua periode (1970–2010 dan 2010–2020) untuk menyortir tren historis dan pergeseran terbaru.


BQ4: Bagaimana musim/tanggal rilis memengaruhi genre dan popularitas film?

Dominasi popularitas summer terbukti konsisten secara visual dan signifikan secara statistik, dipicu konsentrasi genre populer di periode ini.

Heatmap menunjukkan genre populer seperti action, sci-fi, animation, fantasy, dan family terkonsentrasi pada musim panas.



Konsentrasi genre populer ini mendorong rata-rata popularitas summer menjadi yang tertinggi dibandingkan musim lain.



Test	Median	Statistics	p-value
Mann-Whitney U	Summer = 21.3 vs Others = 18.4	U = 1,874,576	0.00001
Kruskal-Wallis (H)	Summer highest median among seasons	H = 34.0	0.00000


Key Takeaway: Hasil uji statistik ($p < 0.05$) menegaskan bahwa konsentrasi genre blockbuster di summer berkontribusi langsung pada rata-rata popularitas tertinggi musim ini, sehingga pola dominasi summer bukan sekadar visual melainkan signifikan secara nyata.

BQ5: Apakah bahasa Inggris merupakan kunci untuk popularitas superior?

Untuk menunjukkan korelasi penggunaan bahasa Inggris terhadap popularitas suatu film, kami menggunakan *scatter plot* film count vs median popularity.

Scatter Plot menunjukkan keberadaan bahasa non-Inggris dengan median popularity lebih tinggi dari film berbahasa Inggris

Selain itu, terdapat bukti konkret bahwa terdapat film berbahasa selain Inggris yang berhasil meraih popularitas top 1% data global



	movie_title	language	popularity
0	Jujutsu Kaisen 0	ja	1444.117
1	Demon Slayer -Kimetsu no Yaiba- The Movie: Mug...	ja	802.132
2	The Grandmother	es	639.160

Penggunaan bahasa Inggris **bukan kunci utama** untuk menjamin popularitas film.


Penggunaan bahasa **selain Inggris** terbukti berhasil menghasilkan **film dengan popularitas tinggi**.

Note: Data yang bersifat *outlier* malah berguna pada analisis ini untuk mencari kasus spesial di mana suatu film berbahasa non-Inggris berhasil menciptakan tren (menyebabkan popularitas yang sangat tinggi)

BQ6: Bagaimana urutan pentingnya faktor yang memengaruhi popularitas?

Kami memanfaatkan model gradient boosted decision trees CatBoost untuk mendapatkan urutan faktor yang memengaruhi popularitas secara keseluruhan

Feature importance berdasarkan model gradient boosted decision trees CatBoost



Untuk memastikan kredibilitas model, digunakan K Fold Cross Validation sebanyak 5 fold yang menghasilkan metrik sebagai berikut

CatBoost Evaluation	
MAE	22,280
R ²	0,0834

Business questions (BQ) insights

1 Film multi-genre konsisten menunjukkan distribusi popularitas lebih tinggi dibandingkan single-genre.

2 Terdapat diminishing return setelah jumlah genre melewati 5, di mana peningkatan popularitas melandai dan tidak lagi signifikan.

3 Kombinasi genre blockbuster (action, sci-fi, fantasy) terbukti meningkatkan popularitas, sementara kombinasi drama-romance cenderung lemah.

4 Mei-Agustus menjadi puncak popularitas akibat tren summer blockbusters, menjadikannya periode rilis paling krusial.

5 Film berbahasa non-Inggris juga dapat mencapai median popularitas tinggi.

6 Faktor paling berpengaruh terhadap popularitas adalah genre, diikuti oleh timing rilis, sementara faktor lain lebih minor.

Business value

1 Studio dapat merilis film yang memadukan lebih dari satu genre, menarik audiens yang lebih luas, meningkatkan potensi komersial.

2 Studio dapat menyusun film dengan kombinasi genre yang tepat (3-5) untuk memperluas audiens tanpa kehilangan fokus cerita.

3 Produser bisa memprioritaskan kombinasi genre yang terbukti sinergis untuk memaksimalkan potensi box office.

4 Rilis di musim panas berpotensi memaksimalkan popularitas dan pendapatan, menjadikannya strategi kunci industri film.

5 Ada peluang bagi studio untuk menargetkan pasar global/non-Inggris, meningkatkan diversifikasi dan penetrasi pasar.

6 Fokus utama strategi film harus pada pemilihan genre dan waktu rilis; optimasi faktor lain hanya bersifat pendukung.

Terima Kasih!
