




End-to-End Pothole Semantic Segmentation with Data Driven Strategy and EoMT Model



Data Science Competition

Dibawakan oleh **Tim ARB**



Haegen Q.



Nathaniel J.R.



Bob K.

Dari ancaman nyawa hingga defisit PDB, skala kerusakan jalan di Indonesia telah menjadi kritis dan membutuhkan intervensi teknologi yang nyata

31,91% jalan rusak di Indonesia



30% kecelakaan lalu lintas disebabkan oleh masalah infrastruktur termasuk kerusakan jalan

3 orang

Meninggal setiap jam akibat kecelakaan lalu lintas

~3% PDB

Menjadi kerugian negara akibat kecelakaan lalu lintas



Deteksi *pixel-perfect* dengan *semantic segmentation*



Input gambar mentah



Mask semantic segmentation

1. Estimasi material terukur dengan mengekstrak luas secara spesifik
2. Penentuan skala prioritas untuk memprioritaskan perbaikan pada titik kritis
3. Otomatisasi dan skalabilitas membuat evaluasi menjadi efisien

Transisi menuju pemeliharaan jalan berbasis AI/ML *computer vision* menjadi sebuah langkah konkret untuk menekan angka fatalitas dan kerugian ekonomi


Sebagai solusi, kami membangun *pipeline* komprehensif yang *data-driven*, dimulai dari analisis data hingga evaluasi inferensi secara holistik

Pipeline pothole semantic segmentation

Dice Coefficient


=

$$\frac{2TP}{2TP + FP + FN}$$



Distribusi *training* dan *test set* yang menunjukkan variasi karakteristik lubang yang menuntut observasi mendalam

Distribusi data *train* dan *test* pada dataset Data Science ARA 7.0




Terdapat juga 498 gambar *mask* sebagai *ground truth training*




Berdasarkan analisis terhadap *training set* dan *mask*, terdapat ketimpangan pada karakteristik gambar *training* yang berpotensi memicu bias

Distribusi kepadatan (*density*) lubang pada gambar *training*



Distribusi frekuensi/jumlah lubang pada gambar *training*



Insight

#1

Didominasi dengan kepadatan rendah, menunjukkan *imbalance* piksel lubang dengan background & berisiko amnesia terhadap kelas minoritas

Insight


#2

Lebih dari separuh gambar (56%) hanya memuat 1-2 lubang, membuat model rentan gagal pada kondisi jalan yang rusak parah secara berkelompok

Tidak hanya kepadatan dan jumlah lubang, terdapat juga ketimpangan berdasarkan rata-rata luas dan posisi spasial lubang pada gambar *training*



Distribusi rata-rata luas lubang pada gambar *training*




Insight

#3

Dominasi lubang berukuran besar (69,7%) membuat model berisiko gagal mendeteksi lubang berukuran kecil

Heatmap distribusi lokasi spasial lubang pada gambar *training*



Insight

#4

Kecenderungan lubang yang sangat *centered bias* membuat model rentan menghafal posisi tengah dan bukan bentuk lubangnya

Sementara itu, Laplacian Variance dan Mean Pixel Intensity menunjukkan *blurriness* dan *brightness* seluruh gambar berada pada *range* yang normal

Distribusi data *train* dan *test* pada dataset Data Science ARA 7.0

Insight

#5

Kualitas gambar yang dominan tajam memungkinkan untuk mempertahankan fitur tekstur asli tanpa perlu komputasi ekstra untuk koreksi ketajaman

Distribusi data *train* dan *test* pada dataset Data Science ARA 7.0

100%

Gambar pada *Training* dan *Test Set* Memiliki *Range* Intensitas Brightness yang Normal (50 – 200)

Dengan P_i adalah *pixel intensity* (grayscale)

$$\text{Brightness: } \mu = \frac{1}{N} \sum_{i=1}^N P_i$$

Insight

#6

Tidak adanya anomali pencahayaan juga menjustifikasi efisiensi kita untuk menonaktifkan augmentasi kecerahan (*brightness*) pada *pipeline*


Menjawab tantangan yang ditemukan pada tahap EDA, berikut adalah strategi yang telah didesain secara spesifik

Kode	Masalah	Solusi <i>Preprocessing</i>
Insight #1	Ketimpangan <u><i>pothole density</i></u> : risiko bias dan mengabaikan kerusakan jalan berskala kecil	<u>Dice Loss</u> sebagai <i>loss function</i> dan <u><i>stratified split</i></u> berdasarkan persentase kepadatan piksel lubang dan penggunaan
Insight #2	Ketimpangan jumlah <u><i>pothole</i></u> : berisiko membuat model rentan gagal pada kondisi jalan rusak parah secara berkelompok	<u>Augmentasi Random Crop</u> untuk memecah gambar besar menjadi beberapa <i>patch</i>
Insight #3	Ketimpangan rata-rata luas <u><i>pothole</i></u> : hasil dari pembagian <i>density</i> dengan jumlah <i>pothole</i>	<u>Augmentasi geometris Aggressive Zoom-Out</u> untuk memaksa model mempelajari lubang berukuran sangat kecil
Insight #4	<u><i>Center bias</i></u> lokasi spasial <u><i>pothole</i></u> : berisiko membuat model menghafal posisi tengah dan gagal mendeteksi posisi lainnya	<u>Augmentasi geometris Shift Scale Rotate</u> (menggeser secara acak posisi lubang) agar model memiliki <i>spatial invariance</i>
Insight #5	<u>Kualitas gambar test yang lebih baik</u>	<u>Menonaktifkan augmentasi blur</u> (seperti Gaussian Blur atau Motion Blur) untuk mempertahankan <i>high-fidelity texture</i>
Insight #6	<u><i>Brightness</i> normal untuk seluruh gambar</u>	<u>Menonaktifkan augmentasi intensitas cahaya</u> (Random Brightness) mengingat pencahayaan seluruhnya normal

Melanjutkan proses stratifikasi, diterapkan strategi augmentasi geometris dan spasial yang agresif

Stratifikasi berdasarkan *pothole density* dengan *holdout* 80/20

Stratified, 80% Train, 20% Validation



Augmentasi spasial dan geometris berbasis data

1. Shift Scale Rotate (probabilitas 80%) termasuk Shift dan Aggressive Zoom Out
2. Grid Distortion (probability 50%), mensimulasikan berbagai sudut pandang
3. Horizontal Flip (probability 50%)
4. Vertical Flip (probability 50%)
5. Coarse Dropout (probability 30%), sebagai *regularization tool*

Contoh augmentasi pada train_045.jpg




Image resizing dan normalization diterapkan guna menstabilkan konvergensi, proses *learning* juga dikalibrasi melalui *hybrid loss function*

Resize & normalize untuk mempercepat & menstabilkan konvergensi



416 × 277 px (train_217.jpg augmented)

resize & normalize



512 × 512 px, normalized



533 × 300 px (test_316.jpg augmented)

resize & normalize



512 × 512 px, normalized



Mengapa harus *hybrid loss function* (Dice dan BCE)?


Dice Coefficient

=

$$\frac{2TP}{2TP + FP + FN}$$

Dice Loss: Non-Convex Function

BCE Loss: Convex Function



50% Dice Loss + BCE Loss

Perkenalkan EoMT, model yang mendefinisikan ulang standar model State-of-The-Art atas efisiensi performanya dibandingkan SOTA saat ini



Fitur utama pada model Encoder-only Mask Transformer (EoMT)

1

Dibangun di atas Backbone ViT, tanpa adapter dan tanpa lapisan decoder

2


Model memperoleh bias induktif, tercerminkan pada fitur *dense* melalui pra-pelatihan *Masked Image Modeling* (MIM) DINO

3

Mekanisme Joint Self-Attention pada *encoder* memetakan piksel dan object queries secara bersamaan (operasi cross)

4

Dari segi kecepatan *training* dan inferensi, performa model 4x lebih cepat dibandingkan State-of-The-Art Transformer saat ini



Sebagai penyempurnaan akhir, kami mengkalibrasi *hyperparameter* pada EoMT guna mencapai kapabilitas tertinggi model

Seluruh variabel pada *hyperparameter tuning*

Hyperparameter	Nilai		
Optimizer	AdamW		
Learning Rate (Head)	1e-4	1e-5	5e-6
Weight Decay	1e-2	1e-3	5e-4
Learning Rate Scheduler	CosineAnnealingLR	ReduceLRonPlateau	
Early Stop (# Epoch)	5	10	
Max Epoch	12	15	20



Test Time Augmentation (TTA) pada tahap inferensi



Original



Horizontal Flip



Vertical Flip

Agregasi Prediksi



Hasil Averaging


Test Time Augmentation (TTA) menstabilkan hasil prediksi melalui rata-rata output citra asli dan multi-orientasi, secara efektif mempertajam presisi dan mereduksi bias pada batas piksel segmentasi

Evaluasi model secara komprehensif mengukuhkan EoMT sebagai model superior dibandingkan CNN dan Transformer lainnya




Model	Arsitektur Model	Nilai Lokal	Nilai Publik	Nilai Privat
U-Net (<i>baseline</i>)	CNN berbasis ResNet yang mengandalkan <i>decoder</i> berat dengan <u><i>skip-connection</i> untuk mempertahankan detail spasial-lokal terpenting</u>	0.8315	0.7482	0.7658
Segformer	Transformer dengan mekanisme <u><i>Self-Attention</i></u> , yang dapat menangkap <u>fitur penting pada gambar</u> , dengan <i>decoder</i> sederhana berupa <i>Multi Layer Perceptron</i>	0.8456	0.7580	0.7890
EoMT DINOv3	Transformer, yang <u>menghapus adapter dan lapisan <i>decoder</i></u> , sepenuhnya digantikan dengan <u>Joint Self-Attention</u>	0.8727★	0.8034★	0.8207★

Analisis Prediksi vs Ground Truth: Mengukur Ketangguhan Model dan Mengidentifikasi Area Kendala



Analisis Entropi untuk Mengidentifikasi Karakteristik Kritis pada Deteksi Pothole



Error Analysis menggunakan *Entropy Heatmap*

Entropy

$$H = -p \log_2(p) - (1 - p) \log_2(1 - p)$$

Result

#1

Tiap instansi *pothole* memiliki peta persebaran entropi yang berbeda-beda, bahkan 2 ujung pada pothole sama bisa kontras

Result

#2


Terdapat suatu kelas yang tidak muncul di statistik namun signifikan secara kualitatif: *Pothole* tanpa *edge* (garis batas)

Result

#3

Edge kurang jelas sehingga entropi lebih tinggi dari biasanya, menunjukkan keraguan model pada daerah tersebut.


Harmonisasi *preprocessing* yang *data-driven* dengan kapabilitas mutakhir EoMT menghasilkan *pipeline* segmentasi dengan performa terbaik



Stratifikasi berbasis *pothole density* berhasil mengeliminasi bias dan merepresentasikan *pothole* berskala kecil



Model EoMT berbasis DINOv3 menjadi model yang mencapai nilai Dice Coefficient tertinggi



Transformasi spasial dan geometri yang agresif berhasil mengatasi *center bias* dan bias pada jumlah dan rata-rata luas *pothole*



Test Time Augmentation (TTA) secara signifikan memperkuat ketahanan prediksi dan menajamkan batas piksel segmentasi

Public Leaderboard Rank: 1 ARB



Public Dice: 0.80345

Private Leaderboard Rank: 2 ARB



Private Dice: 0.82071

Terima Kasih!

Appendix

Efisiensi komputasi *real-time* dan reduksi *Segment Errors* untuk operasi sistem otomasi skala besar menjadi fokus lanjutan di masa depan



Ekspansi dataset lintas wilayah dengan mengintegrasikan data eksternal dari berbagai topografi jalan raya untuk memperkuat generalisasi model



Memperluas skema regularisasi untuk menjaga ketahanan model terhadap anomali visual dunia nyata



Mengompresi beban komputasi arsitektur model agar dapat di-*deploy* dan bekerja secara *real-time* pada kamera *dashboard* kendaraan



Formula Image Moment untuk menghitung luas area *pothole* (moment 0) dan pusat *pothole* (moment 1)



Rumus Image Moment (p dan q adalah Moment)

$$M_{pq} = \sum_x \sum_y x^p y^q I(x, y)$$

Menghitung Luas Lubang dengan Moment ke-0

$$M_{00} = \sum_x \sum_y x^0 y^0 I(x, y) = \sum_x \sum_y I(x, y)$$

Menghitung Pusat Massa (Centroid Sumbu X dan Y) dengan Moment ke-1

$$M_{10} = \sum_x \sum_y x \cdot I(x, y)$$

$$C_x = \frac{M_{10}}{M_{00}}$$

$$M_{01} = \sum_x \sum_y y \cdot I(x, y)$$

$$C_y = \frac{M_{01}}{M_{00}}$$

Note:

$I(x, y) = 1$ untuk pixel putih

$I(x, y) = 0$ untuk pixel hitam



Penurunan formula Laplacian (kalkulus) menjadi matriks konvolusi yang cocok untuk perhitungan atau manipulasi terhadap data gambar



Laplacian

$$\Delta I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$



$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Aproksimasi gradien tanpa limit

$$\text{Selisih Maju: } f'(x) \approx f(x+1) - f(x)$$

$$\text{Selisih Mundur: } f'(x) \approx f(x) - f(x-1)$$

Aproksimasi Laplacian 1D: selisih antara selisih maju & mundur

$$f''(x) \approx [f(x+1) - f(x)] - [f(x) - f(x-1)]$$

$$f''(x) \approx f(x+1) - 2f(x) + f(x-1)$$

Turunan kedua X dan Y





$$\frac{\partial^2 f}{\partial x^2} \approx f(x+1, y) - 2f(x, y) + f(x-1, y)$$

$$\frac{\partial^2 f}{\partial y^2} \approx f(x, y+1) - 2f(x, y) + f(x, y-1)$$


Penggabungan Persamaan (menjadi aproksimasi Laplacian)

$$\nabla^2 f(x, y) \approx f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y)$$

Lebih dalam tentang arsitektur model Encoder-only Mask Transformer (EoMT) berdasarkan sumber *paper original*-nya



Arsitektur model DINOv3 (Distillation with No labels) sebagai backbone EoMT yang digunakan pada *pipeline pothole semantic segmentation*



Multi-crop





Global views



Local views



Beberapa *highlights* kemajuan pada model DINOv3 berdasarkan sumber *paper original*-nya



Cosine Similarity Maps


Beberapa *highlights* kemajuan pada model DINOv3 berdasarkan sumber *paper original*-nya




Unsupervised Object Discovery



Img in Chesapeake




PCA DINOv2




PCA DINOv3



Img in Chesapeake



Segmentation v3



Canopy height v3

Versatile Applications in Remote Sensing