

Analisis Prediktif dan Deskriptif Rentang Gaji Berdasarkan Informasi pada Curriculum Vitae Menggunakan Gradient-Boosted Trees

1st Nathaniel Jonathan Rusli
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Kota Bandung, Indonesia
omgitsnathaniels@gmail.com

2nd Peter Wongsoredjo
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Kota Bandung, Indonesia
peterwongsoredjo@gmail.com

3rd Maheswara Bayu Kaindra
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung
Kota Bandung, Indonesia
kaindramaheswara11@gmail.com

Abstract—Proses *recruitment* manual, khususnya pada tahap *shortlisting*, seringkali membutuhkan biaya besar dan berisiko menambahkan beban pada organisasi. Tanpa acuan gaji yang jelas, perusahaan berpotensi menawarkan kompensasi yang tidak seimbang, sementara kandidat kerap menghindari negosiasi sehingga kehilangan peluang gaji yang wajar. *Curriculum Vitae* (CV) sebagai dokumen standar memuat informasi penting mengenai latar belakang, pengalaman kerja, keterampilan teknis, dan sertifikasi pelamar kerja yang dapat dimanfaatkan untuk memprediksi rentang gaji yang objektif. Dalam penelitian ini, dikembangkan sebuah *pipeline* rekayasa fitur yang komprehensif dengan fokus pada ekstraksi sinyal prediktif dari data kualitatif. Tahapan ini mencakup *encoding* ordinal, operasi regex, ekstraksi indikator kunci dari fitur, hingga pemetaan domisili yang tidak terstruktur ke dalam kluster regional. Model prediksi dieksplorasi dengan tiga algoritma *gradient-boosted trees* (CatBoost, XGBoost, dan LightGBM) dengan metrik *Mean Absolute Error* (MAE) yang ditujukan untuk memprediksi rentang gaji dan memahami faktor yang memengaruhinya. Penelitian menunjukkan model CatBoost memberikan performa yang paling optimal untuk task prediksi rentang gaji berbasis data pada CV. Analisis *feature importance* dan SHapley Additive exPlanations (SHAP) mengidentifikasi *candidate level*, *total working experience*, dan *tech stack* sebagai faktor utama dalam estimasi gaji.

Keywords—prediksi gaji, curriculum vitae, gradient-boosted trees, CatBoost, SHAP.

I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi dalam beberapa dekade terakhir mengubah cara berbagai pihak mengambil keputusan dan menjalankan aktivitasnya. Salah satu bidang yang mengalami kemajuan signifikan adalah *data science*, yaitu disiplin yang memanfaatkan data untuk menggali pengetahuan baru [1] melalui pola, yang pada akhirnya dapat digunakan untuk membuat prediksi yang mendukung proses pengambilan keputusan.

Dalam konteks dunia profesional, *data science* membuka peluang baru untuk meningkatkan efisiensi dan objektivitas, salah satunya dalam proses rekrutmen. Salah satu kebutuhan penting dalam rekrutmen adalah memperkirakan upah yang rasional berdasarkan ekspektasi calon pekerja. Perhitungan upah didasarkan oleh faktor-faktor seperti latar belakang pendidikan, pengalaman kerja [2], keahlian teknis, hingga sertifikasi yang dimiliki. Dengan melakukan analisis data, perusahaan dapat memperoleh estimasi rentang gaji yang lebih objektif dan konsisten. Pemodelan ini juga membantu dalam menyusun strategi keuangan yang adil, sekaligus

mempermudah kandidat mendapatkan gambaran upah standar sesuai dengan profil mereka.

Proses rekrutmen yang dilakukan secara manual, khususnya pada tahap *shortlisting* memakan biaya dan waktu yang cukup besar. Posisi lowongan yang tidak segera terisi mengurangi produktivitas, menunda pencapaian organisasi, dan berpotensi membengkakkan biaya [3]. Selain itu, tanpa adanya acuan mengenai ekspektasi gaji, perusahaan berisiko menawarkan kompensasi yang tidak seimbang, membebani anggaran tim dan menghilangkan kandidat potensial.

Dari perspektif kandidat, sebagian besar kandidat maupun pekerja menghindari negosiasi rentang gaji oleh karena satu dan lain hal. Kegagalan menegosiasikan rentang gaji yang diharapkan menyebabkan hilangnya peluang mendapatkan gaji yang sebanding [4]. Dibutuhkan adanya acuan rentang estimasi gaji yang berdasar dari faktor-faktor seperti latar belakang pendidikan, pengalaman kerja, keahlian teknis, hingga sertifikasi yang dimiliki, bagi pencari kerja maupun pekerja. Dengan analisis data, perusahaan tidak hanya mengandalkan intuisi dan penilaian subjektif, tetapi juga membangun model prediktif yang objektif [5].

1.2 Rumusan Masalah

1. Metode pembersihan dan transformasi apa yang dapat digunakan untuk menangani data CV yang kompleks sehingga dapat diolah secara efektif untuk keperluan prediksi gaji?
2. Faktor-faktor apa saja yang paling signifikan dalam memengaruhi rentang gaji calon pekerja?
3. Bagaimana strategi *feature engineering* yang mampu merepresentasikan karakteristik kandidat secara komprehensif sehingga dapat meningkatkan performa model prediksi?
4. Model *machine learning* apa yang memiliki performa terbaik dalam memprediksi rentang gaji (*estimate bottom* dan *estimate up*) berdasarkan metrik evaluasi yang digunakan?

1.3 Tujuan dan Manfaat

Penelitian ini bertujuan untuk:

1. Mengembangkan metode pembersihan dan transformasi data CV yang kompleks agar dapat diolah secara efektif untuk kepentingan prediksi gaji.

2. Mengidentifikasi faktor-faktor yang paling berkontribusi dalam memengaruhi rentang gaji calon pekerja.
3. Merancang *feature engineering* yang mampu merepresentasikan karakteristik kandidat secara komprehensif, guna meningkatkan performa model prediksi.
4. Membangun dan membandingkan performa model *machine learning* yang mampu memprediksi estimasi gaji bawah dan estimasi gaji atas secara akurat berdasarkan metrik evaluasi yang sesuai.

II. PEMBAHASAN

2.1. Landasan Teori

A. Regression Tree-Based Models

Decision Tree adalah model prediktif yang mempartisi ruang data secara rekursif menjadi subruang yang membentuk basis prediksi. Penggunaan *Decision Tree* secara umum terbagi menjadi dua, klasifikasi dan regresi. *Regression Tree* digunakan untuk memprediksi target nilai yang berupa nilai numerik kontinu, dengan galat prediksi diukur dengan selisih antara nilai yang diamati dan nilai yang diprediksi [6].

Proses pemilihan partisi dilakukan dengan mengevaluasi kemungkinan atribut dan threshold untuk membagi data. Untuk setiap kandidat pemisahan, algoritma akan menghitung pengurangan kesalahan prediksi yang dapat dicapai, biasanya diukur melalui *Cost Function*. Pada setiap iterasi, dicari split terbaik yang meminimalkan galat *node* turunan dengan *node* induknya [7].

B. Gradient-Boosted Trees

Algoritma *Boosting* menggabungkan sejumlah *weak learners*, model yang sedikit lebih baik daripada tebakan acak, menjadi *strong learner* secara iteratif. *Gradient Boosting* bertujuan untuk menemukan aproksimasi $\hat{F}(x)$, dari fungsi $F^*(x)$, yang memetakan x ke nilai y , dengan meminimalisir ekspektasi nilai dari suatu fungsi kerugian, $L(y, F(x))$. Proses akan menambahkan *decision tree* secara bertahap ke model, di mana secara matematis proses m akan dinyatakan sebagai

$$F_m(x) = F_{m-1}(x) + \rho_m h_m(x)$$

Di mana ρ_m merupakan bobot fungsi ke- m dari model $h_m(x)$. Inisiasi algoritma gradient boosting dilakukan dengan membuat aproksimasi awal dari fungsi target, dengan konstanta α , yang dipilih untuk meminimalkan total kerugian pada seluruh data, fungsi tersebut dinyatakan dalam

$$F_0(x) = \underset{\alpha}{\operatorname{argmin}} \sum_{i=1}^N L(y_i, \alpha)$$

Model-model selanjutnya diharapkan untuk meminimalisir fungsi kerugian dengan memperbaiki kesalahan estimasi dari model sebelumnya (residual/pseudo-residual). Fungsi kerugian secara matematis dinyatakan sebagai

$$(\rho_m, h_m(x)) = \underset{i=1}{\operatorname{argmin}} \sum_{i=1}^N L(y_i, F_{m-1}(x_i) + \rho h(x_i))$$

Dengan demikian, setiap pohon dapat dipandang sebagai suatu langkah dalam algoritma *gradient descent* yang berfungsi untuk mengoptimasi fungsi $F^*(x)$ [8].

C. CatBoost

CatBoost merupakan pustaka *gradient boosting* yang bertujuan untuk mengurangi *shift* pada prediksi yang terjadi ketika pelatihan. *Prediction shift* adalah perbedaan distribusi antara prediksi pada data latih dengan prediksi data uji, karena pada pelatihan, *gradient boosting* menggunakan data latih yang sama untuk menghitung gradien maupun untuk melatih model yang meminimalkan gradien tersebut, menimbulkan bias.

Untuk itu, *CatBoost* menggunakan pendekatan *Ordered Boosting*. Dengan menggunakan permutasi acak dalam pelatihan, *CatBoost* memastikan bahwa gradien suatu contoh hanya dihitung menggunakan model yang tidak pernah dilatih dengan contoh tersebut. Pada iterasi ke- m , akan dibangun serangkaian model dasar, di mana model ke- i pada iterasi tersebut akan dilatih menggunakan data dari *instance* pertama hingga ke- i , dan nantinya akan digunakan untuk menghitung gradien *instance* ke- $i+1$. Implementasi *CatBoost* dioptimasi sehingga hanya satu model yang dibangun per iterasi, yang mencakup seluruh permutasi dan model. Sehingga independen dari urutan awal data, proses ini diulang untuk beberapa permutasi acak.

Selain itu, salah satu fitur penting *CatBoost* adalah pendekatannya dalam menangani fitur kategorial. Pada *CatBoost*, fitur kategorial disubstitusi dengan fitur numerik yang mengukur estimasi target untuk setiap kategori. Untuk mencegah *over-fitting*, nilai estimasi target suatu *instance* dihitung hanya menggunakan *instance* sebelumnya dalam permutasi acak. Dengan ini, *CatBoost* mampu memanfaatkan fitur kategorial tanpa adanya kebocoran data [8].

D. eXtreme Gradient Boosting (XGBoost)

XGBoost adalah *decision tree ensemble* berbasis *gradient boosting* yang dirancang untuk lebih efisien dan *scalable*. Cara kerja *XGBoost* hampir sama seperti *gradient boosting*, membangun model dengan secara aditif menambahkan *decision tree*, dengan tambahan fungsi regularisasi ke dalam fungsi objektif. Secara matematis fungsi objektif tersebut dinyatakan dengan

$$L_{xgb} = \sum_{i=1}^N L(y_i, F(x_i)) + \sum_{m=1}^M L\Omega(h_m)$$

dengan

$$\Omega(h) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

di mana T merupakan jumlah daun, w adalah nilai prediksi pada daun, γ adalah konstanta kontrol kompleksitas, dan λ adalah regularisasi L2 untuk mencegah overfitting. Dengan regularisasi pada fungsi tersebut, *XGBoost* mampu membentuk pohon yang lebih sederhana melalui strategi *pre-pruning*.

XGBoost menggunakan *shrinkage* yang mengurangi kontribusi tiap pohon, menyebabkan pelatihan model lebih cepat, serta meringankan penyimpanan. *XGBoost* juga melakukan penanganan data sparse dalam mencari *best split*, dengan mengabaikan nilai nol dan juga *missing value* saat menghitung split, mempercepat pelatihan. Untuk membantu mengurangi overfitting, *XGBoost* menerapkan *Row* dan *Column subsampling*, dengan randomization untuk generalisasi [8].

E. Light Gradient Boosting Machine (LGBM)

Light Gradient Boosting Machine (LGBM) merupakan salah satu library yang merupakan implementasi dari algoritma *gradient boosting* yang dikembangkan untuk meningkatkan efisiensi komputasi. Implementasi LGBM memanfaatkan prekomputasi histogram serta *selective sampling*, banyak *learning hyper-parameters* yang memungkinkan model bekerja dalam banyak jenis skenario.

Fitur utama yang membedakan LGBM dari varian *gradient boosting* lainnya adalah penerapan Gradient-based One-sided Sampling (GOSS) dan Exclusive Feature Bundling (EFB). GOSS merupakan strategi sampling yang memprioritaskan sampel dengan nilai gradien terbesar (sampel tersebut dianggap lebih informatif terhadap arah model). Di luar itu, sebagian kecil sampel dengan gradien rendah tetap digunakan dengan bobot yang disesuaikan. Pendekatan tersebut memungkinkan LGBM untuk mengurangi ukuran data pelatihan tanpa kehilangan banyak informasi penting, sehingga mempercepat proses training. EFB berfungsi menggabungkan fitur-fitur yang cenderung *sparse* dan individual. Dengan ini, jumlah fitur dapat ditekan, karena fitur-fitur individual tersebut tidak aktif bersamaan. Kedua mekanisme ini menjadikan LGBM sangat efisien dalam kecepatan training dan penggunaan memori [8].

2.2. Metode Penelitian

A. Dataset Overview

Data yang digunakan dalam penelitian ini berasal dari kompetisi Kaggle berjudul Talent Salary Prediction Model DAC yang mencakup informasi yang terdapat pada *curriculum vitae* (CV) serta estimasi rentang gaji ([https://www.kaggle.com/competitions/salary-prediction-model/](https://www.kaggle.com/competitions/salary-prediction-model)). Dataset yang digunakan terdiri dari 14 variabel bebas yang merupakan kombinasi antara data kategorial dan numerik dengan proporsi yang tampak pada Tabel I. Sementara itu, variabel terikat mencakup “Estimate Bottom” dan “Estimate Up”. Kedua variabel menyajikan informasi yang dapat digunakan untuk *training* model dalam memprediksi batas tinggi dan batas rendah gaji berdasarkan informasi pada variabel terikat.

TABEL I. PROPORSI KATEGORI VARIABEL BEBAS

	Kategorial	Numerik
Jumlah	3	11
Proporsi	21,43%	78,57%

Dataset ini terdiri dari 1.160 baris untuk *training* dan 290 baris untuk *testing* dengan informasi dasar mengenai *training dataset* yang dapat dilihat pada Tabel II.

TABEL II. INFORMASI TERKAIT VARIABEL BEBAS

Nama Fitur	Unique	Missing
ID	1160	0
Current Position	549	141
Targeted Position	21	958
Total Working Experience	18	0
Candidate Level	5	0
Domisili	436	99
Education 1	1122	18
Education 2	519	629
Education 3	124	1031
Expected Benefit Bottom	24	0
Expected Benefit Up	13	0
Notice Period	17	1103
Tech Stack	1144	5
Certification	442	359

Sesuai Tabel II, sebagian fitur memiliki kardinalitas yang tinggi, seperti “Current Position”, “Domisili”, “Education 1”, “Education 2”, “Education 3”, “Tech Stack”, dan “Certification”. Fitur “ID” juga secara wajar memiliki kardinalitas yang sangat tinggi dengan fungsinya sebagai *identifier*. Menelusuri nilai dari masing-masing fitur lebih lanjut, muncul indikasi akan dibutuhkannya proses *data cleaning* dan *feature engineering* untuk mengekstraksi informasi yang lebih bermakna dari data mentah yang tampak *random*.

Tidak hanya kardinalitas, entri pada *dataset* tidak memiliki nilai duplikat. Selain itu, tampak juga sebagai fitur yang memiliki banyak *missing values*. Dengan asumsi bahwa nilai yang hilang pada *dataset* merepresentasikan informasi tersendiri, yaitu tidak disajikannya informasi tersebut oleh pelamar kerja, maka penanganan terhadap *missing values* perlu disesuaikan dengan pendekatan yang tepat.

B. Data Cleaning and Preprocessing

Dalam analisis data, permasalahan yang umum ditemukan adalah inkonsistensi dan ketidaklengkapan pada dataset mentah. Kondisi tersebut dapat berupa nilai yang hilang (*missing values*) hingga format penulisan yang tidak seragam. Permasalahan tersebut berpotensi menurunkan kualitas analisis dan mengurangi akurasi model prediksi. Untuk menyelesaikan permasalahan tersebut, diperlukan proses *data cleaning*.

Data cleaning merupakan proses pengolahan data yang mencakup identifikasi dan peningkatan kualitas dan konsistensi data dengan mengurangi error pada *data warehouse*. Dalam konteks ini, *Data cleaning* meningkatkan kualitas analisis data dan prediksi (*machine learning*) melalui format yang lebih bersih dan konsisten.

Ruang lingkup *data cleaning* pada penelitian ini difokuskan pada dua teknik utama, yaitu penanganan *missing values* dan normalisasi teks. Penanganan *missing*

values memastikan tidak ada kekosongan data yang dapat mengganggu kinerja algoritma, sedangkan normalisasi teks ditujukan untuk menyatukan representasi kosakata secara kategorikal. Kedua pendekatan ini sesuai dengan karakter dataset yang digunakan, di mana sebagian besar atribut memiliki kardinalitas tinggi.

1) Penanganan Missing Values

Penanganan nilai yang hilang merupakan teknik mengisi nilai yang tidak ada dengan suatu nilai sementara. Penanganan *missing values* untuk penelitian ini dilakukan dengan mengubah seluruh nilai NaN pada dataset menjadi label “Unknown”.

Feature		Feature	
1	X	1	X
2	NaN	2	Unknown
3	NaN	3	Unknown
4	Y	4	Y

Fig. 1. Contoh Penanganan Missing Values

Pendekatan ini dipilih untuk mempertimbangkan keberadaan data yang tidak lengkap sebagai suatu kategori yang valid, alih-alih menghapus dan menyebabkan banyaknya informasi berharga yang hilang atau mengimputasinya yang bersifat spekulatif. Misalnya “Targeted Position”, “Domisili”, “Education”, dan “Certification” yang diasumsikan memang sengaja tidak disajikan atau tidak dimiliki oleh pelamar kerja.

Adapun pengecualian pada fitur “Notice Period” yang dihapus sepenuhnya dari *dataset* akibat *missing value* yang terlalu tinggi serta *unique value* yang tidak memberikan cukup informasi baik untuk diinterpretasikan, maupun untuk *training* bagi model *machine learning*. Strategi ini juga dipilih karena penggunaan model CatBoost (*baseline model* dalam penelitian ini) untuk pelatihan model yang mampu menangani nilai kategorial dengan *ordered target-encoding* bawaannya tanpa proses *encoding* tambahan. Label “Unknown” dapat diperlakukan sebagai sebuah kategori sehingga ketidaklengkapan data tidak menjadi masalah besar bagi pelatihan model.

2) Normalisasi Teks

Normalisasi teks merupakan teknik pembersihan teks berdasarkan format yang sudah ditentukan. Pada jangkauan penelitian ini, normalisasi teks dilakukan untuk menstandarkan atribut yang memiliki variasi penulisan, seperti *Current Position*, *Targeted Position*, *Tech Stack*, *Certification*, dan domisili berdasarkan informasi *unique* pada Tabel II.

Variasi penulisan tersebut meliputi perbedaan istilah (penggunaan sinonim), singkatan, dan kesalahan pengetikan yang menyebabkan duplikasi kategori. Untuk mendapatkan kata dengan format berbeda-beda, digunakan implementasi *regular expression* (regex).




Fig. 2. Contoh Normalisasi Teks pada *Current Position*

Pendekatan ini menghasilkan data yang lebih terstruktur dan konsisten, sehingga memudahkan proses pengolahan pada tahap *feature engineering* dan pelatihan model.

C. Feature Engineering and Selection

Untuk meningkatkan interpretabilitas dan performa *training* pada model, dilakukan *feature engineering* berdasarkan karakteristik dari masing-masing fitur. Setelah itu, dilakukan *feature selection* dengan metode *filtering* dan *forward sequential feature selection* untuk memperoleh fitur yang paling relevan bagi pemodelan. Metode *filtering* dilakukan dengan memilih fitur dengan *feature importance* yang memberikan dampak dan tidak redundan atau menghasilkan *noise* bagi model. Metode *forward sequential feature selection* dilakukan untuk memperoleh himpunan fitur yang paling relevan bagi pemodelan.

Berikut merupakan penjabaran atas proses *feature engineering* yang juga telah diseleksi melalui *feature selection*:

1) ID

Berdasarkan Tabel II, terlihat bahwa “ID” memiliki nilai kardinalitas yang sangat tinggi, yaitu 1160 data unik. Kondisi tersebut dapat mengakibatkan ketidakstabilan prediksi model *training* (khususnya berbasis *tree*). Analisis lebih lanjut terhadap pola ID menunjukkan bahwa format yang umum ditemukan adalah “SKU-XXXXYYY” dengan “XXXX” berupa alfabet dan “YYY” berupa tiga atau empat digit numerik.

Berdasarkan pengamatan tersebut, “ID” diekstraksi menggunakan *regular expression* (regex) menjadi dua komponen utama: (1) *company code* yang direpresentasikan oleh empat karakter alfabet, (2) *registration order* berupa nomor pendaftaran kandidat. Dengan pendekatan ini, “ID” yang semula berupa label unik dapat diturunkan menjadi atribut yang terstruktur dan berpotensi memberi informasi.




Fig. 3. Distribusi Company Code Setelah Normalisasi

Berdasarkan figur di atas, terlihat bahwa terdapat kluster kode empat huruf yang sama, yang menandakan bahwa terdapat pola (misal kode perusahaan) yang dapat digunakan untuk pemodelan. Fitur *company code* diuji dalam model berbasis *gradient tree*. Hasil pengujian menunjukkan adanya peningkatan kecil terhadap skor ketika fitur tersebut dilibatkan. Walaupun skor akurasi meningkat pada data *train*, model memperlihatkan indikasi *overfitting* ketika diuji dengan data *test*. Hal ini menandakan bahwa meskipun fitur turunan dari "ID" memiliki struktur, kontribusinya terhadap target prediksi tidak optimal.

2) Current Position dan Targeted Position

Berdasarkan Tabel II, tampak bahwa terdapat kardinalitas yang besar pada fitur "Current Position", dengan adanya 549 *unique value* yang disebabkan oleh variasi penulisan pada CV yang ada. Dengan demikian, kita lakukan pemetaan posisi yang ada dengan regex menjadi grup posisi yang lebih general, memungkinkan kita untuk mengubah kardinalitas "Current Position" menjadi 29 dengan count yang jauh lebih tinggi sebagai bentuk generalisasi seperti yang terlihat pada Fig. 4. Begitu pula dengan "Targeted Position" mentah dengan kardinalitas 21 turun menjadi 14. Hasil pemetaan ini tidak hanya menyederhanakan variasi, tetapi juga meningkatkan konsistensi fitur sehingga lebih mudah dipelajari oleh model.




Fig. 4. Bar Chart "Current Position" Mentah vs Terstandarisasi

3) Total Working Experience

Berdasarkan heatmap korelasi pada Fig. 5, tampak bahwa "Total Working Experience" memiliki korelasi yang cukup kuat, yaitu sebesar 0,7 terhadap "Estimate Up" dan 0,69 terhadap "Estimate Bottom".

Heatmap Korelasi Total Working Experience terhadap Rentang Gaji




Fig. 5. Heatmap Korelasi "Target Working Experience" dengan Target

Berdasarkan pemetaan "Total Working Experience" terhadap rata-rata rentang gaji ("Estimate Up" dan "Estimate Bottom" pada Fig. 6, tampak bahwa "Total Working Experience" memiliki korelasi yang positif.




Fig. 6. Bar Chart "Target Working Experience" Terhadap Rentang Gaji

Karena "Total Working Experience" merupakan fitur numerikal dan dapat diinterpretasikan dengan mudah, maka fitur ini tidak dimodifikasi lebih lanjut dan dapat langsung digunakan untuk *training*.

4) Candidate Level

Pada Fig. 7 tampak ordinalitas yang jelas pada sepanjang rata-rata rentang gaji dari satu tingkatan ke tingkatan "Candidate Level" lainnya.




Fig. 7. Bar Chart Rata-Rata Rentang Gaji per “Candidate Level”

Dengan ini, untuk menegaskan terdapatnya ordinalitas pada tingkatan “Candidate Level”, maka dilakukan pemetaan masing-masing kategori tingkatan sebagai berikut: (1) Fresher: 0, (2) Entry-Level: 0, (3) Junior: 1, (4) Mid-Level: 2, dan (5) Senior: 3, sesuai dengan urutan rata-rata rentang gaji yang meningkat (kandidat dengan Candidate Level Fresher hanya memiliki frekuensi kemunculan 1 di seluruh *training dataset* dan memiliki rentang gaji yang serupa dengan “Candidate Level” Entry-Level).

5) Domisili

Salah satu tantangan terbesar pada fitur “Domisili” adalah nilai atau informasi yang sangat tidak terstandarisasi seperti yang dapat dilihat pada Fig. 8, di mana misalnya Bandung memiliki lebih dari satu format yang valid. Hal ini menyebabkan tingginya kardinalitas data, di mana banyak variasi teks yang merujuk ke wilayah yang sama. Dengan ini, diperlukan proses normalisasi teks dengan bantuan operasi *regular expression* (regex) dan peta kamus wilayah. Normalisasi meliputi penghapusan simbol, spasi, kata-kata tidak relevan, hingga penyamaan ejaan (misalnya “Tanggerang” menjadi “Tangerang”).

```
Domisili
Bandung          94
Jakarta, Indonesia 77
Jakarta          56
Bandung, Indonesia 35
Bandung, Jawa Barat 19
..
Jakarta Selatan, Indonesia 1
Pemalang         1
Probolinggo, Indonesia 1
Tangerang - Banten 1
Pasuruan, Indonesia 1
Name: count, Length: 436, dtype: int64
```

Fig. 8. Frekuensi Nilai Fitur Domisili

Selanjutnya, masing-masing domisili dipetakan ke dalam kategori regional yang lebih representatif, tidak hanya membersihkan data, tapi juga memetakannya ke dalam *bucket* yang didasari kesetaraan tingkat upah minimum (UMR), misalnya seperti “Jabodetabek”, “Bandung”, “Surabaya”, hingga kelompok agregat yang lebih general seperti “Sumatra”, “Sulawesi”, dan kelompok regional lainnya. Dengan demikian, fitur “Domisili” yang telah diaplikasikan *feature engineering* mampu menangkap variasi gaji antarwilayah yang lebih terukur, sekaligus mengurangi *noise* akibat penulisan alamat yang tidak standar.

6) Education (1, 2, dan 3)

Melihat Fig. 9., tampak bahwa entri pendidikan ditulis dengan sangat beragam: ada yang lengkap dengan nama universitas, jurusan, serta tahun, hanya yang hanya mencantumkan nama universitas beserta jurusan, ada pula yang bercampur dengan informasi *bootcamp* atau kursus singkat. Kondisi ini menjadi dasar dalam pembuatan fitur baru melalui *feature engineering* agar informasi yang tersebar dapat diringkas, dinormalisasi, serta digunakan secara efektif oleh model *machine learning*.

Education 1	Education 2	Education 3
JENDERAL SOEDIRMAN UNIVERSITY (2020 - now) Bac...	NaN	NaN
Pasundan University - Bachelor's Degree - Info...	NaN	NaN
STMIK PRANATA INDONESIA, INFORMATION SYSTEMS, ...	NaN	NaN
INFORMATICS ENGINEERING 2024\STATE ISLAMIC UN...	INFORMATICS ENGINEERING 2021\NSUMATERA INSTITU...	SCIENCE 2017\NTRI SUKSES BOARDING SCHOOL - SEN...
Computer Science, Andalas University, 2013-2019	IPA, SMA N 5 Bukittinggi, 2010-2013	NaN
Mercu Buana University, Informatics Engineerin...	NaN	NaN
2015 - 2019 S1 Matematika, FMIPA\Universitas ...	2020 Bootcamp Android Developer\Arkademy Tech...	NaN
Software Engineering\2016 - 2018 SMKN 4 Pad...	NaN	NaN
University Al-Azhar Indonesia - Jakarta, Indon...	IPB University - Bogor, Jawa Barat May 2019 - ...	NaN
Telkom University, Industrial Engineering, Mar...	NaN	NaN

Fig. 9. Sample Fitur “Education 1”, “Education 2”, dan “Education 3”

Berikut merupakan fitur-fitur baru hasil *feature engineering* yang telah dibuat:

- Highest Education:** Karena jenjang pendidikan yang ditempuh oleh seorang profesional memiliki pengaruh terhadap gaji, maka dibuat fitur “Highest Education” berupa teks (SMA, D3, S1, S3, dst.) misalnya “Computer Science, Andalas University, 2013–2019” menjadi S1. Selain itu, dibuat juga fitur “Highest Education Ordinal” yang merupakan versi ordinal dari fitur sebelumnya untuk secara eksplisit memberikan suatu tingkatan terhadap jenjang pendidikan, misal SMA/SMK diubah menjadi angka 1, D3 menjadi angka 2, S1/D4 menjadi angka 3, dst.
- Education Count:** Tidak seluruh kandidat memiliki jumlah riwayat pendidikan yang sama sehingga dibuat fitur “Education Count” untuk membandingkan jumlah informasi latar belakang antarkandidat.
- Has Bootcamp or Certificate:** Meskipun redundan terhadap fitur dasar “Certification”, informasi *bootcamp* atau kursus singkat yang dimiliki oleh kandidat tetap bersifat informatif.
- Is Top Uni dan Is Foreign Uni:** Dengan banyaknya asal universitas kandidat, maka dibuat fitur “Is Top Uni” dan “Is Foreign Uni” yang menandakan apakah kandidat berasal dari universitas top (seperti UI, UGM, ITB, Telkom University, Universitas Padjadjaran, dst.) atau luar negeri (seperti MIT, Harvard, Monash, dst.) yang berpotensi menjadi sinyal diferensiasi gaji akibat ekspektasi daya saing dan paparan internasional yang dimiliki kandidat.

7) Expected Benefit (Bottom dan Up)

Berdasarkan Fig. 10, terlihat bahwa nilai Expected Benefit (Bottom maupun Up) memiliki sebaran yang sangat bervariasi, dengan sebagian pelamar kerja menuliskan nilai nol, sementara sebagian lainnya menetapkan ekspektasi yang sangat tinggi hingga muncul *outlier*. Kondisi ini menunjukkan bahwa tidak hanya nilai absolut yang penting, tetapi juga jarak antara “Expected Benefit Bottom” dan “Expected Benefit Up” sebagai indikator fleksibilitas kandidat dalam negosiasi gaji. Oleh karena itu, dibuat fitur “Expected Spread”, baik dalam bentuk selisih absolut untuk menangkap variabilitas ekspektasi gaji sekaligus meningkatkan interpretabilitas serta ketahanan model terhadap *outlier*.




Fig. 10. Hubungan “Expected Benefit Bottom” dan “Expected Benefit Up” Terhadap “Estimate” Bottom” dan “Estimate Up”

8) Notice Period

Fitur “Notice Period” pada *dataset* menunjukkan distribusi nilai yang tidak konsisten, banyak mengandung entri yang tidak terstandarisasi, serta memiliki proporsi *missing values* yang tinggi (sebanyak 1.103 dari 1.160 entri). Dengan ini, fitur “Notice Period” diputuskan untuk dihapus secara keseluruhan pada tahap *feature engineering*. Keputusan ini bertujuan untuk menyederhanakan model dan memastikan hanya fitur yang relevan serta informatif yang digunakan dalam proses pelatihan.




Fig. 11. Frekuensi Nilai Fitur “Notice Period”

9) Tech Stack

Fitur “Tech Stack” pada *dataset* merupakan teks bebas dengan banyak variasi penulisan. Dilakukan tokenisasi untuk memecah setiap entri ke dalam token individual seperti *Python*, *php*, *Tensorflow*. Selanjutnya, token-token tersebut digunakan untuk menghasilkan beberapa fitur turunan:

a) Total Tech Stack

Dihitung jumlah *tech stack* yang terdapat pada masing masing kandidat. Fitur ini menggambarkan luasnya keahlian yang dimiliki oleh seorang kandidat, yang secara intuitif berkorelasi positif dengan ekspektasi gaji, karena menunjukkan fleksibilitas yang lebih tinggi dalam pekerjaan. Fig. 12 menunjukkan adanya distribusi normal pada total *tech stack* yang dimiliki para kandidat, menunjukkan kondisi pasar yang kompetitif.




Fig. 12. Distribusi Jumlah Tech Stack Per Kandidat

b) Group Spread

Token dipetakan ke dalam beberapa *macro skill groups* seperti devops, data/ML, dan frontend. Hasil pemetaan ini menunjukkan sebaran keterampilan tiap kandidat di berbagai kelompok untuk mengidentifikasi generalisasi dan spesialisasi keterampilan kandidat. Dengan adanya pemetaan ke dalam kelompok makro, model dapat lebih mudah mengenali pola hubungan antara area kompetensi dan kisaran gaji yang diharapkan.




Fig. 13. Rata-rata *Coverage Skill Group* per Kandidat

c) Rare Skill Count

Tidak semua keterampilan dalam “Tech Stack” memiliki bobot yang sama, layaknya beberapa keterampilan sangat jarang ditemui, dan bisa menjadi penanda diferensiasi kandidat. Dengan demikian dibentuklah fitur “Rare Skill Count” untuk mengukur berapa banyak keterampilan langka yang dimiliki seorang kandidat. Sebuah keterampilan didefinisikan sebagai langka apabila memenuhi dua kriteria:

- *Threshold* Frekuensi Global: Keterampilan muncul pada $< 10\%$ kandidat.
- *Minimum Document Frequency*: Keterampilan muncul pada ≥ 25 kandidat, mencegah keterampilan outlier yang muncul hanya sekali tetap dihitung.

Fig. 14 menunjukkan sampel dari Rare Skill yang terdapat dalam lautan *tech stack* pada *dataset*. Dengan definisi ini, fitur “Rare Skill Count” menangkap keunikan portofolio keterampilan yang dapat meningkatkan nilai tawar kandidat di pasar kerja.




Fig. 14. Rare Skills berdasarkan Frekuensi Kandidat

10) Certification

Berdasarkan tinjauan pada Fig. 15, tampak bahwa fitur “Certification” tidak selalu terisi (terdapat total 359 *missing values*) dengan format beragam string “[]” atau *list* berisi sertifikasi dengan format JSON. Dengan ini, para pelamar kerja memiliki jumlah sertifikasi dan *domain* keahlian yang bervariasi antarkandidat.

```

333      ["Architecting on AWS (Membangun Arsitektur\nC...
445                                           NaN
798                                           NaN
275                                           []
864                                           []
107                                           NaN
917      ["Java Programming Digitalent Scholarship, Uni...
581      ["Docker", "PHP", "SQL Fundamentals - Solo Learn...
376                                           []
1094                                           NaN
673                                           NaN
Name: Certification, dtype: object

```

Fig. 15. Sample Fitur “Certification”

Dengan ini, pelamar dengan *missing values* pada fitur “Certification” pun dianggap tidak memiliki sertifikasi, sama dengan data pelamar kerja yang memiliki nilai “[]”. Indikator memiliki atau tidaknya sertifikasi pun ditandai pada fitur “Has Certification” yang memiliki nilai biner (0/1). Selain itu, masing-masing jumlah dan kategori sertifikasi yang dimiliki pelamar kerja ditandai pada fitur “Certification Count” yang bernilai numerik dan fitur “Certification Category” yang menyediakan berbagai kategori sertifikasi yang umum (lihat Fig. 16).




Fig. 16. “Certification Category” berdasarkan Frekuensi Kandidat

Dengan fitur “ID” dan “Notice Period” yang dihapus seluruhnya dari *dataset*, berikut merupakan ringkasan

seluruh fitur hasil *feature engineering* dan *feature selection* yang dipilih untuk *training* dan *testing* pada model:

TABEL III. FITUR HASIL FEATURE ENGINEERING DAN FEATURE SELECTION

Nama Variabel	Fitur yang Dihasilkan dan Dipilih
Current Position	“Current Position” (Tersegmentasi)
Targeted Position	“Targeted Position” (Tersegmentasi)
Total Working Experience	Total Working Experience (tidak mengalami perubahan)
Candidate Level	“Candidate Level” (Sudah dipetakan berdasarkan kardinalitas)
Domisili	“Domisili” (Tersegmentasi)
Education 1	“Highest Educational Ordinal”, “Highest Education”, “Has Bootcamp or Certificate”, “Is Top Uni”, “Is Foreign Uni”
Education 2	
Education 3	
Expected Benefit Bottom	“Expected Benefit Bottom”, “Expected Benefit Up”, “Expected Spread”
Expected Benefit Up	
Tech Stack	“Group Count Programming Languages”, “Group Count Frontend”, “Group Count Backend Web”, “Group Count Databases”, “Group Count Cloud/DevOps”, “Group Count Data/ML”, “Group Count Testing/QA”, “Group Count Mobile”, “Group Count Product Design/PM”, “Group Total Covered”, “Rare Skill Count”
Certification	“Has Certification”, “Certification Count”, “Certification Category”

D. Model Training and Evaluation

Untuk melakukan prediksi terhadap rentang gaji, dilakukan *training* dengan menggunakan model CatBoost sebagai *baseline model*. Model CatBoost dipilih karena kemampuannya dalam menangani variabel kategorial secara langsung tanpa memerlukan proses *one-hot encoding* sehingga memudahkan pemodelan dengan data CV yang penuh dengan fitur kategorial yang mayoritas memiliki kardinalitas tinggi. Dengan *target* gaji yang ganda (batas atas dan batas bawah), dilakukan *training* pada dua model berbeda untuk memprediksi masing-masing batas gaji.

Metrik evaluasi yang digunakan adalah Mean Absolute Error (MAE) dengan menghitung rata-rata MAE pada prediksi “Estimate Bottom” dan “Estimate Up” yang mulanya dihitung secara terpisah. Rumus MAE dapat didefinisikan sebagai:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Untuk menjaga stabilitas dan bias pada hasil evaluasi, digunakan juga K-Fold Cross Validation (CV), yang mana membagi *training dataset* ke dalam *K* lipatan (*folds*) yang sama besar. Secara bergantian, satu lipatan (*fold*) digunakan sebagai data validasi sementara *K-1* lipatan lainnya digunakan untuk *training* pada model. Pada penelitian ini digunakan *K* sebesar 5, dengan rasio *training* dan *validation data size* sebesar 4:1. Pendekatan ini memberikan gambaran

yang lebih realistis terhadap kemampuan generalisasi model terhadap data baru.

Guna mengatasi sifat target yang bersifat diskrit, prediksi model yang serupa bernilai kontinu dilakukan proses pembulatan ke kategori rentang gaji yang telah ditentukan (seperti yang tampak pada Fig. 17). Mekanisme ini bekerja dengan cara membandingkan hasil prediksi dengan titik batas terdekat dari himpunan kelas gaji. Dengan demikian, setiap prediksi akhir selalu berada pada kelas gaji yang valid sesuai distribusi data aktual.




Fig. 17. Distribusi Nilai “Estimate Bottom” dan “Estimate Up”

E. Model Selection

Pada tahap *model selection*, dilakukan *training* dan validasi menggunakan beberapa model berbasis gradient-boosted trees lainnya, antara lain eXtreme Gradient Boosting (XGBoost) dan Light Gradient Boosting Machine (LGBM). Proses pemilihan model dilakukan dengan membandingkan performa prediksi dari masing-masing algoritma berdasarkan metrik Mean Absolute Error (MAE) yang dijalankan menggunakan K-Fold CV seperti pada tahap *model training* dan *evaluation*.

F. Model Explainability

Dalam upaya memahami pengaruh dan kontribusi masing-masing terhadap hasil prediksi, penelitian ini menggunakan dua pendekatan *model explainability*. Pertama, *feature importance* bawaan model untuk memperoleh gambaran global mengenai fitur-fitur yang paling berpengaruh dalam memprediksi estimasi rentang gaji. Kedua, metode SHapley Additive exPlanations (SHAP) yang memungkinkan interpretasi lebih mendalam baik secara lokal, maupun global.

2.3. Hasil dan Pembahasan

A. Lingkungan Eksperimen

Eksperimen berupa *training* dan validasi model dilakukan pada Kaggle Notebook *environment*, sebuah lingkungan berbasis *cloud computing* yang telah dikonfigurasi dengan perangkat keras dan perangkat lunak untuk tugas *machine learning*. Implementasi dilakukan dengan menggunakan Python 3.10 serta *library data analysis* dan *science*: Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn, CatBoost, XGBoost, LightGBM. Digunakan juga *library* pendukung lainnya seperti *ast* untuk pemrosesan *list*, *re* untuk operasi regex, *unicode data* untuk normalisasi teks, *scipy* untuk pemrosesan matriks, dan *Counter* untuk menghitung frekuensi kemunculan elemen dalam sebuah *collection*. Digunakan juga suatu *random seed* (bernilai 42 untuk penelitian ini) untuk seluruh komponen

yang melibatkan *randomness*. Konfigurasi perangkat keras dan lunak yang digunakan pada lingkungan Kaggle telah diringkas pada Tabel IV.

TABEL IV. LINGKUNGAN PERANGKAT KERAS DAN LUNAK EKSPERIMEN

Komponen	Spesifikasi
CPU	Intel® Xeon® 2.20 GHz (1 <i>virtual core</i>)
RAM	13-16 GB
Storage	73 GB (disk sementara)
OS	Ubuntu 20.04 LTS (Kaggle container)

B. Hasil Evaluasi Model

Hasil eksperimen menggunakan tiga model gradient-boosted trees, yakni CatBoost, XGBoost, dan LightGBM dapat dilihat pada Tabel V.

TABEL V. PERFORMA (MAE) VALIDASI MODEL

Model	Mean Absolute Error (MAE)
CatBoost	1.164.009
XGBoost	1.288.923
LightGBM	1.243.084

CatBoost memperoleh nilai MAE paling rendah di antara ketiga model gradient-boosted trees, diikuti oleh LightGBM dan juga XGBoost. Dengan pendekatan *ordered boosting* dan juga permutasi acak, CatBoost mampu menangani berbagai macam fitur kategorial yang terdapat dalam *dataframe*, menghasilkan model yang lebih stabil dan akurat.

XGBoost bekerja dengan *one-hot encoding* untuk menangani data kategorial, sehingga jumlah kategori yang sangat banyak, bisa menghasilkan matriks yang besar dan sangat sparse. Hal ini membuat pohon sulit menemukan split yang benar-benar informatif, karena sebagian besar kolom berisi nol, menyebabkan nilai MAE yang cukup tinggi.

LightGBM menunjukkan keunggulan dari sisi kecepatan pelatihan dengan menggunakan teknik *Gradient-based One-Side Sampling (GOSS)* dan *Exclusive Feature Bundling (EFB)*. Meskipun demikian, dalam menangani data kategorial dengan *sparsity* yang cukup besar, terdapat penurunan akurasi pada LightGBM, menyebabkan nilai MAE nya sedikit di atas CatBoost.

C. Feature Importance & SHAP Analysis

Penjabaran *feature importance* pada Fig. 18 menunjukkan bahwa “Candidate Level” merupakan fitur dengan kontribusi terbesar terhadap prediksi gaji, dengan bobot sekitar 68%, menandakan pentingnya jenjang posisi terhadap ekspektasi gaji. “Tech Stack Categories” (7,66%) serta “Total Working Experience” (6,00%) juga memegang peranan yang cukup kuat terhadap prediksi gaji, menggambarkan bagaimana keterampilan serta pengalaman kerja memegang peranan penting dalam estimasi gaji. Fitur lainnya seperti “Current Position”, “Domisili”, dan “Highest Education” juga menentukan estimasi gaji seseorang,

bersesuaian dengan bagaimana posisi, daerah, dan juga edukasi seseorang menentukan ekspektasi gaji.




Fig. 18. Feature Importance Model Prediksi

Pada Fig. 19, posisi titik pada sumbu horizontal (nilai SHAP) menunjukkan arah dan besar pengaruh fitur terhadap prediksi gaji, nilai positif mendorong prediksi ke arah gaji lebih tinggi, sedangkan nilai negatif sebaliknya. Secara keseluruhan, grafik memperlihatkan bahwa model tidak hanya dipengaruhi oleh faktor tunggal, tetapi merupakan kombinasi antara level kandidat, pengalaman kerja, posisi, lokasi, serta distribusi keterampilan teknis. Pola warna merah yang konsisten menegaskan validitas hubungan intuitif antara nilai fitur yang tinggi dengan prediksi gaji yang lebih besar.




Fig. 19. SHAP Beeswarm Feature Importance

D. Feature Analysis

1) Candidate Level

Mengacu kembali ke Fig. 19, fitur “Candidate Level” menunjukkan pengaruh paling dominan terhadap ekspektasi gaji. Nilai SHAP yang tinggi pada level ordinalitas, yaitu pada jabatan Mid-Level hingga Senior mengindikasikan korelasi positif yang kuat, sehingga semakin tinggi posisi kandidat, semakin besar pula ekspektasi gaji. Sebaliknya, Nilai SHAP yang rendah pada jabatan Junior hingga Fresher menandakan bahwa ordinalitas jabatan yang rendah menyebabkan adanya penurunan ekspektasi gaji. Hal ini konsisten dengan intuisi dunia nyata, di mana jabatan merupakan indikator utama pengalaman dan tanggung jawab, sehingga secara langsung berhubungan dengan kompensasi.

2) Tech Stack

Fig. 20 menjelaskan secara lebih rinci bagaimana masing-masing kategori dalam “Tech Stack Categories” mempengaruhi prediksi gaji. Kategori Mobile merupakan kategori paling berpengaruh dalam estimasi gaji, diikuti kategori Cloud/Devops. Hal ini mengindikasikan bagaimana penguasaan *tech stack* di bidang *mobile* dan juga Cloud/Devops saat ini memberikan kontribusi signifikan pada estimasi gaji kandidat. SHAP memberikan justifikasi kuantitatif mengenai bagaimana masing-masing kategori memengaruhi prediksi, serta pemetaan tech stack secara langsung berdampak pada performa model yang tercermin dari nilai MAE.




Fig. 20 SHAP Feature Importance Kategori Tech Stack

Fig. 19 memperlihatkan korelasi positif antara “Tech Stack Count” dan juga “Rare Skills Count” terhadap estimasi gaji kandidat. Temuan ini menandakan bahwa semakin banyak total “Tech Stack” yang dikuasai seseorang, maka akan semakin besar pula ekspektasi gaji yang diterimanya, begitu halnya dengan “Rare Skills” yang dimilikinya. Fig. 21 memperjelas korelasi ini dengan pola yang cukup konsisten bahwa semakin banyak “Rare Skills” yang dimiliki, semakin tinggi pula median estimasi gaji.




Fig. 21. Distribusi Rare Skills terhadap Estimasi Atas Gaji

3) Total Working Experience

Fitur “Total Working Experience” juga menunjukkan korelasi positif terhadap prediksi gaji pada Fig. 19. Kandidat dengan total pengalaman kerja lebih panjang cenderung mendorong estimasi gaji ke arah yang lebih tinggi, menggambarkan fenomena kenaikan gaji pekerja seiring bertambahnya pengalaman dan total kontribusi untuk perusahaan. Meskipun demikian, variasi penyebaran SHAP

pada fitur ini juga menunjukkan efek pengalaman tidak sepenuhnya homogen, melainkan dipengaruhi oleh faktor lain seperti jabatan atau keahlian teknis.

4) Current Position dan Targeted Position

Fig. 22 menggambarkan perbedaan yang cukup jelas antara kelompok posisi dengan median gaji tertinggi dan terendah. Posisi spesialis layaknya DevOps Engineer, dan iOS Developer, menunjukkan kesenjangan gaji yang signifikan dengan posisi umum seperti Content Writer, Security Engineer, ataupun IT Support. Dengan mengelompokkan variasi posisi ke dalam kategori yang terstandarisasi, model mampu menangkap pola pada fitur kategorial. Temuan ini menegaskan bahwa posisi spesialisasi dan kebutuhan pasar terhadap suatu keahlian akan memengaruhi estimasi kompensasi yang ditawarkan.




Fig. 22. Median Gaji terhadap Current Position

5) Domisili

Distribusi gaji rata-rata pada Fig. 23 menunjukkan perbedaan rata-rata gaji berdasarkan domisili. Wilayah pusat ekonomi seperti Jabodetabek dan Bandung cenderung memiliki median gaji yang lebih tinggi dibandingkan daerah lain. Boxplot menunjukkan banyaknya *outlier*, menandakan adanya individu dengan ekspektasi gaji yang melebihi rata-rata di hampir semua wilayah. Beberapa daerah dengan jumlah kandidat kecil seperti Nusa Tenggara menunjukkan median tinggi namun kurang dapat merepresentasikan keseluruhan daerah. Grafik menegaskan bahwa domisili berperan sebagai indikator penting yang memengaruhi ekspektasi gaji, dengan adanya UMR yang berbeda antar daerah, meskipun faktor lain dapat memengaruhi kandidat untuk melebihi ekspektasi gaji rata-rata.




Fig. 23 Distribusi Gaji Rata-Rata terhadap Domisili

6) Education

Fig. 24 memberikan gambaran lebih dalam mengenai kontribusi fitur-fitur turunan edukasi terhadap estimasi gaji. Fitur *Edu Count* mencakup seluruh edukasi baik formal maupun non-formal yang ditempuh kandidat sehingga kurang merepresentasikan korelasi antara total edukasi dengan gaji. Edukasi formal yang ditempuh oleh kandidat terlihat dalam fitur “Highest Education Ordinal”, yang menunjukkan korelasi positif dengan peningkatan gaji semakin tinggi pendidikan yang ditempuh kandidat. Institusi di mana kandidat menempuh pendidikan juga berpengaruh dalam estimasi kompensasi yang akan didapatkan. Kandidat yang menempuh pendidikan lanjut di universitas favorit memiliki kelebihan kompetitif di pasar kerja, terlihat dari grafik yang menggambarkan adanya korelasi positif pada fitur “Is Top Uni” untuk setiap kandidat yang memenuhi fitur tersebut. Selain itu, pendidikan di luar negeri juga menunjukkan adanya korelasi positif terhadap estimasi gaji. Temuan ini menunjukkan bahwa perusahaan akan mengompensasi kandidat lebih apabila kandidat menempuh pendidikan lanjut, terlebih di universitas luar negeri ataupun universitas favorit.




Fig. 24 Grafik SHAP Fitur Edukasi terhadap Gaji

Fitur “Highest Education” pada Fig. 24 merupakan data kategorial yang perlu ditelaah lebih lanjut korelasi nilai kategori di dalamnya dengan estimasi gaji. Fig. 25 menggambarkan distribusi gaji rata-rata terhadap pendidikan tertinggi yang ditempuh kandidat. Secara umum, kandidat yang menempuh pendidikan S1/D4 ke atas, memiliki median gaji rata-rata di kisaran Rp. 10.000.000,00. Sedangkan kandidat yang hanya menempuh pendidikan hingga D3 bahkan SMA/SMK, memiliki median gaji yang lebih rendah. Hal ini menunjukkan intuisi pasar, di mana kandidat dengan jenjang pendidikan yang lebih tinggi akan diberikan kompensasi yang lebih besar, sesuai dengan ilmu yang diterima kandidat.




Fig. 25 Distribusi Gaji Rata-Rata terhadap Edukasi Tertinggi

7) Certification

Fig. 26 menunjukkan SHAP value seluruh *feature engineering* yang didapatkan melalui fitur “Certification”. Kandidat yang memiliki “Certification” (“Has Certificate”) cenderung memperlihatkan kestabilan bahkan nilai positif terhadap estimasi gaji, di mana keberadaan sertifikasi memberikan kontribusi yang jelas dalam meningkatkan prediksi gaji. Begitu pula dengan sertifikasi *bootcamp* yang dimiliki kandidat juga menunjukkan korelasi positif, menunjukkan adanya kontribusi positif kepada peningkatan gaji. Kandidat yang tidak memiliki sertifikasi sama sekali cenderung mengalami penurunan pada prediksi gaji. Selain itu, total sertifikasi yang dimiliki suatu peserta juga memperlihatkan peningkatan gradual terhadap gaji yang diprediksi.




Fig. 26. Plot Beeswarm Fitur Edukasi

“Certification Category” pada Fig. 26 menunjukkan distribusi SHAP value yang variatif sehingga diperlukan pemetaan lebih lanjut kategori sertifikasi dan hubungannya dengan Gaji. Fig. 27 memberikan gambaran penuh mengenai median gaji yang dimiliki per kategori sertifikasi yang dimiliki oleh kandidat. Dengan sertifikasi *security* memegang median gaji tertinggi, menunjukkan bahwa kandidat yang memiliki sertifikasi *security* umumnya memiliki estimasi gaji di atas Rp. 10.000.000,00.




Fig. 27. Distribusi Median Gaji per Kategori Sertifikasi

E. Temuan Utama Penelitian

1) Transformasi Data CV

Data CV yang terdiri dari berbagai fitur dengan kardinalitas dan kompleksitas yang tinggi memerlukan transformasi yang efektif. *Dataset* CV yang tinggi *sparsity* dengan banyak *missing values* pertama dibersihkan dengan mengisi *value* tersebut dengan “Unknown”. Setelah itu, perlu dibangun *pipeline* pembersihan terstruktur yang menormalisasi teks bebas dan menyatukan variasi penulisan.

Pada fitur posisi, baik itu “Current Position” maupun “Targeted Position”, diberlakukan standarisasi regex dari 549 label mentah menjadi 29 posisi pekerjaan bermakna, dengan *outlier* seluruhnya digabung ke label “other”. Serupa dengan proses normalisasi fitur posisi, fitur Domisili juga memetakan *dataset* domisili kandidat ke dalam kluster wilayah seperti Jabodetabek, Bandung, dst. untuk mengurangi kardinalitas yang tinggi pada varietas penulisan domisili pada *dataset*.

Fitur “Tech Stack” merupakan *array* seluruh *tech stack* yang dimiliki oleh seorang kandidat. Dilakukan normalisasi seluruh item yang terdapat dalam fitur (*lowercase*, varian *.js*, dst.), pemetaan sinonim untuk *tech stack* yang serupa, deduplikasi keterampilan kandidat, dan tokenisasi *tech stack* menjadi objek singular. Hal serupa juga dilakukan dalam standarisasi fitur “Certification”, yang bertipe sama seperti fitur “Tech Stack”, *array* yang berisikan seluruh sertifikasi yang dicantumkan kandidat. Sertifikasi yang tercantum kemudian dinormalisasi, dan dipetakan ke dalam kategori general, mengurangi kardinalitas, dan memungkinkan prediksi yang lebih stabil.

Pipeline pembersihan yang dilakukan mengubah data CV yang sebelumnya heterogen, dengan kardinalitas, kompleksitas, dan juga *sparsity* yang tinggi menjadi kumpulan fitur yang konsisten, sederhana, dan siap untuk dimodelkan dalam gradient-boosted trees tanpa kehilangan konteks penting.

2) Peningkatan Performa Model Prediksi Melalui Feature Engineering

Feature engineering yang tepat dapat meningkatkan performa model prediksi, meningkatkan keakuratan model, menghasilkan nilai kerugian yang lebih rendah. *Feature engineering* pada analisis kali ini didasarkan pada penelitian, survey dan pengetahuan penulis mengenai pasar kerja. Melalui *dataset* yang diberikan, beberapa *Exploratory Data Analysis* dilakukan untuk mendapatkan *insight* data, dan bagaimana *insight* tersebut dapat diterapkan menjadi fitur. Beberapa *feature engineering* dilakukan pada analisis dengan kombinasi fitur baru dapat menurunkan *noise*, mengurangi *sparsity* sehingga nilai MAE dapat turun, dan menghasilkan model prediksi yang stabil dan juga akurat.

Feature engineering dilakukan pada fitur “Tech Stack”, untuk setiap token *tech stack* yang dibentuk, dibentuk fitur tambahan berupa “Total Tech Stack”, “Group Spread” (coverage di macro-groups: Cloud/DevOps, Mobile, Backend, dsb.), dan juga “Rare Skill Count”. Fitur ini diekstraksi untuk menghilangkan kebutuhan model untuk melakukan komputasi pada kombinasi *tech stack* yang dimiliki oleh setiap kandidat, dengan kardinalitas yang terlalu tinggi. Melalui fitur tambahan ini, model dapat mengklasifikasi keterampilan yang dimiliki pengguna dalam data numerik.

Pada fitur “Certification”, dilakukan hal serupa, di mana untuk menghindari komputasi model hanya menggunakan kumpulan sertifikasi kandidat yang kompleks, fitur baru di ekstraksi berupa fitur “Has Certification”, “Certification Count”, dan “Certification Category”, untuk mengubah

sertifikasi mentah menjadi data numerik untuk menangkap kredensial profesional.

Fitur “Education” yang awalnya terbagi menjadi 3 bagian yaitu Education 1, 2, dan 3 diekstraksi menjadi beberapa fitur yaitu “Highest Education String”, “Highest Education Ordinal”, dan indikator *top/foreign university*. Fitur edukasi yang awalnya hanya berupa kumpulan teks tanpa makna, kita ubah menjadi fitur pemetaan yang menunjukkan total pendidikan yang ditempuh, pendidikan terakhir yang ditempuh oleh pengguna, dan apakah pendidikan terakhir tersebut memiliki kualitas yang lebih.

Dengan demikian, *dataset* mentah yang awalnya berisikan fitur kategorial dengan teks tak bermakna yang menyebabkan kardinalitas menjadi tinggi, dapat diekstraksi menjadi fitur-fitur yang dapat menggambarkan bobot asli keterampilan, maupun pendidikan dan sertifikasi yang dimiliki peserta, memberikan nilai pada keunggulan kandidat sebagai pembeda bagi model prediksi.

3) Model Machine Learning

Berdasarkan perbandingan ketiga gradient-boosted trees yaitu CatBoost, LightGBM, dan juga XGBoost, terlihat bahwa CatBoost dapat mengungguli kedua model lainnya dalam mengolah data CV dan melakukan prediksi estimasi gaji. Berdasarkan metrik evaluasi Mean Absolute Error (MAE), CatBoost menghasilkan MAE terbaik sebesar 1,164 juta, dibandingkan dengan LightGBM dengan total 1,243 juta dan juga XGBoost dengan total 1,289 juta. CatBoost unggul karena penanganan kategori terurut (*ordered target statistics* atau *ordered target encoding*) yang dimilikinya mampu mengurangi *prediction shift* pada fitur kategorial layaknya posisi, dan domisili, yang mendominasi *dataset* CV. Kemampuan CatBoost untuk mensubstitusi fitur kategorial dengan fitur numerik yang mengukur estimasi target untuk setiap kategori, menjadi alasan utama mengapa model tersebut bisa mengungguli model lain yang kesusahan menangani data kategorial dengan *sparsity* tinggi.

4) Feature Importance dan Analisis

Berdasarkan hasil analisis, ditemukan faktor yang paling mendominasi estimasi kompensasi suatu kandidat adalah fitur “Candidate Level”, sebagai representasi senioritas seorang kandidat dalam perusahaan, di mana semakin tinggi jabatan yang dimilikinya, semakin besar tanggung jawab yang dia pegang yang bertranslasi langsung ke estimasi gaji. Bersamaan dengan level jabatan, total waktu pengalaman kandidat berkorelasi positif dengan rentang gaji yang akan diterimanya. Faktor krusial lainnya yang memengaruhi rentang gaji adalah “Tech Stack” atau keterampilan yang dikuasai kandidat, melalui jumlah total, sebaran keterampilan pada berbagai kelompok keahlian, hingga keterampilan langka yang dimiliki.

Selain ketiga faktor tersebut, faktor-faktor lain yang dapat meningkatkan ekspektasi rentang gaji adalah domisili di mana kandidat tersebut bekerja, dengan daerah pusat ekonomi cenderung menawarkan kompensasi yang lebih tinggi dibandingkan daerah lainnya. Edukasi yang ditempuh seorang kandidat juga memiliki korelasi positif terhadap estimasi rentang gaji, di mana semakin tinggi pendidikan

yang ditempuh, dan semakin kredibel institusi tempat dia menjalaninya akan meningkatkan rentang gaji seseorang. Begitu pula dengan sertifikasi yang memiliki dampak sama seperti edukasi yang dijalani seorang kandidat.

Dari sudut pandang pemberi pekerjaan, model prediksi yang dikembangkan dapat berfungsi sebagai alat bantu analitik untuk menyaring kandidat secara lebih efisien, meningkatkan optimasi proses rekrutmen. HR dapat menilai kesesuaian kandidat terhadap rentang budget yang tersedia tanpa harus melalui proses negosiasi yang panjang. Selain itu, hasil analitik memberikan landasan yang kuat bagi perusahaan untuk menetapkan kisaran kompensasi yang lebih objektif, sesuai dengan level, pengalaman, dan keterampilan kandidat. Dengan demikian, HR *analytics* dapat menyusun struktur gaji secara adil, mengoptimalkan anggaran rekrutmen dan melakukan benchmarking standar pasar tenaga kerja.

Dari sudut pandang pencari kerja, temuan ini membantu kandidat untuk memahami faktor-faktor yang berkontribusi dalam menentukan nilai pasar mereka. Kandidat dapat menggunakan informasi ini untuk sebagai acuan untuk menegosiasikan rentang gaji yang sesuai dengan nilai pasar mereka, serta merancang strategi pengembangan karier mereka dengan berfokus pada peningkatan level, memperluas *tech stack* mereka pada kategori krusial seperti DevOps, serta menambah pengalaman lain yang relevan. Sertifikasi dan latar belakang pendidikan yang mereka tempuh juga dapat meningkatkan nilai pasar mereka. Dengan demikian, penelitian ini memberikan wawasan praktis bagi pencari kerja untuk memungkinkan kandidat mencapai peningkatan kompensasi secara lebih terarah berdasarkan faktor yang berkontribusi di dalamnya.

III. PENUTUP

1. Kesimpulan

Penelitian ini telah berhasil membangun sebuah model prediktif untuk mengestimasi rentang gaji calon pekerja di Indonesia dengan memanfaatkan informasi dari data CV yang relatif kompleks dan heterogen. Melalui berbagai tahapan seperti *data cleaning* dan *feature engineering*, data yang awalnya tidak terstruktur berhasil diolah menjadi fitur yang konsisten dan informatif. Evaluasi menggunakan tiga algoritma gradient-boosted trees menunjukkan bahwa CatBoost memberikan performa terbaik berdasarkan metrik Mean Absolute Error (MAE), melampaui model *peers*-nya yakni XGBoost dan LightGBM.

Analisis *feature importance* dan SHAP menegaskan bahwa *candidate level*, *total working experience*, serta variasi *tech stack* merupakan faktor paling dominan yang menentukan estimasi rentang gaji, diikuti oleh faktor-faktor pendukung lainnya seperti domisili, pendidikan, dan sertifikasi. Dari sudut pandang perusahaan, model ini dapat berfungsi sebagai alat bantu dalam proses penyaringan kandidat serta perumusan struktur kompensasi yang lebih objektif dan efisien. Sementara dari sudut pandang kandidat, hasil penelitian ini memberikan wawasan mengenai faktor-faktor yang mempengaruhi nilai pasar mereka, sekaligus menjadi acuan dalam negosiasi gaji maupun perencanaan pengembangan karier. Dengan ini, penelitian ini tidak hanya menghasilkan model prediksi yang akurat,

tapi juga diharapkan dapat memberikan kontribusi praktis terhadap peningkatan efisiensi proses *recruitment* dan transparansi pasar tenaga kerja.

IV. DAFTAR PUSTAKA

- [1] T. J. N. Santos, C. L. de O. Araujo, dan H. M. Galvao, "Decision-Making by Data: An Application of Data Science with Cognitive Ergonomics," *International Journal of Advances in Management and Economics*, vol. 7, no. 4, pp. 14–19, Jul.–Aug. 2018. [Online]. Tersedia: <https://managementjournal.info/index.php/IJAME/article/view/495/433>. [Diakses: 19 September 2025].
- [2] A. Aletdinova and M. Bakaev, "Human Capital in the Information Society and the Wage Difference Factors," in *Proceedings of IMS2017*, Saint Petersburg, Russian Federation, Jun. 2017. ACM. [Online]. Tersedia: <https://www.researchgate.net/publication/322134642>. [Diakses: 19 September 2025].
- [3] Zippia, "25+ Crucial Average Cost Per Hire Facts [2023]: All Cost Of Hiring Statistics," *Zippia.com*, 16 Feb 2023. [Online]. Tersedia: <https://www.zippia.com/advice/cost-of-hiring-statistics-average-cost-per-hire/>. [Diakses: 19 September 2025].
- [4] J. A. Davis dan A. D. Newman, "Nervous Nelly," Harvard Business School Case 805-021, Agu. 2004. [Online]. Tersedia: https://www.hbs.edu/ris/Publication%20Files/Nervous%20Nelly_6a3ee0e2-3fac-4485-bfa8-687a35a9a1f2.pdf. [Diakses: 19 September 2025].
- [5] M. Potančok, "Role of Data and Intuition in Decision Making Processes," *Journal of Systems Integration*, vol. 10, no. 3, Oct. 2019. [Online]. Tersedia: <https://www.researchgate.net/publication/352902345>. [Diakses: 19 September 2025].
- [6] L. Rokach, "Decision forest: Twenty years of research," *Information Fusion*, vol. 27, hlm. 111–125, 2016, doi: 10.1016/j.inffus.2015.06.005.
- [7] T. Hastie, R. Tibshirani, dan J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [8] C. Bentéjac, A. Csörgö, dan G. Martínez-Muñoz, "A comparative analysis of gradient boosting algorithms," *Artif Intell Rev*, vol. 54, no. 3, hlm. 1937–1967, 2021, doi: 10.1007/s10462-020-09896-5.